

TD d'analyse de données n°1

L3 MIAGE (Informatique) S1, Université Paris Dauphine – PSL

Exercice 1

Soit un tableau de nombres entiers : $X = (33, 34, 26, 26, 49, 49, 47, 44, 43, 32)$. Calculer :

1. la moyenne et la médiane ;
2. le premier et le troisième quartile ;
3. la variance empirique, l'écart-type et l'écart inter-quartile ;
4. tracer la boîte à moustaches.

Exercice 2

On représente dans le tableau suivant les notes d'élèves à un examen.

élève	note	élève	note	élève	note	élève	note
R. D.	15	F. Z.	11	M. A.	8	I. E.	17
F. B.	14	C. M.	13	D. D.	7	G. L.	14
S. M.	12	N. S.	14	T. K.	12	C. B.	10
A. T.	11	H. V.	17	L. H.	7	V. L.	11
R. J.	13	V. S.	16	G. L.	10	L. L.	10
S. G.	13	P. Z.	16	H. F.	4	B. D.	15

Tracer le tableau des effectifs.

Exercice 3

On s'intéresse aux salaires des employés d'une entreprise. Le tableau de données initial, contenant le salaire de chaque employé, a déjà été traité pour obtenir le tableau des effectifs suivant, indiquant les salaires, et le nombre d'employés qui touche chaque salaire (pour des raisons de lisibilité, ce tableau a été découpé en trois) :

salaire	employés	salaire	employés	salaire	employés
1300	7	1900	3	2500	12
1400	74	2000	4	2600	9
1500	134	2100	11	2700	1
1600	60	2200	17	2800	2
1700	14	2300	16	3000	1
1800	2	2400	22	3200	1

Questions sur l'analyse de données.

1. Donner le nombre d'employés dans l'entreprise, le salaire minimum et le salaire maximum. Donner également les modalités des salaires.
2. Calculer la moyenne, la médiane et le mode des salaires.
3. Montrer que la variance empirique des salaires peut s'écrire :

$$\tilde{\sigma}^2 = \frac{\sum_{i=1}^C n_i (s_i - \bar{s})^2}{\sum_{i=1}^C n_i},$$

où C est le nombre de salaires différents, les $s_1 < s_2 < \dots < s_C$ sont les salaires et, pour tout $1 \leq i \leq C$, n_i est le nombre d'employés touchant le salaire s_i .

4. Calculer la variance empirique et l'écart-type.
5. Calculer le premier quartile, le troisième quartile et l'écart inter-quartile.
6. Tracer l'histogramme des salaires.
7. Commenter l'histogramme. On pourra s'appuyer sur les valeurs calculées pour la moyenne, la médiane, le mode, etc.

Questions sur le traitement des données.

1. Ce tableau a été obtenu par traitement d'un tableau de données initial, contenant le salaire de chaque employé.
À quoi ressemblait le tableau initial ? Tracer un exemple pour ce tableau, en indiquant les *variables* et la nature de chaque *observation*.
2. Les valeurs de salaires vous semblent-elles crédibles ? Indiquer quelle opération de pré-traitement elles ont pu subir.
3. Cette opération de pré-traitement est-elle susceptible de changer les résultats de l'analyse de données ? Si oui, dans quelle mesure ?

Exercice 4

On considère une population de ménages, classée en fonction de leur nombre de parts fiscales :

nombre de parts	1	1.5	2	2.5	3	3.5	4	4.5
nombre de ménages	48	58	136	184	210	122	62	12

1. Proposer une représentation graphique de ce tableau.
2. Tracer le tableau de fréquences.
3. Tracer le tableau de fréquences cumulées ainsi que la représentation graphique correspondante.
4. En déduire une approximation de la médiane, du premier quartile et du troisième quartile.

Exercice 5

On dispose des résultats de campagnes publicitaires effectuées sur l'un des médias suivants : la radio et les journaux. Pour les 9 campagnes effectuées à la radio, les ventes ont atteint les valeurs suivantes : $X_1 = (2.6, 5.3, 5.7, 7.6, 8.4, 8.8, 9.5, 10.8, 10.9)$. Dans le cas des campagnes effectuées dans les journaux, les ventes ont été de $X_2 = (5.3, 5.6, 6.6, 6.7, 7.2, 7.3, 8.5, 9.2, 10.4)$. On cherche à comparer l'efficacité des deux types de campagnes publicitaires.

1. Tracer côte à côte et sur une même échelle les diagramme à moustaches des deux séries de données.
2. Commenter le graphique ainsi obtenu et conclure.