

TD d'analyse de données n°1

L3 MIAGE (Informatique) S1, Université Paris Dauphine – PSL

Exercice 1

Soit un tableau de nombres entiers : $X = (33, 34, 26, 26, 49, 49, 47, 44, 43, 32)$. Calculer :

1. la moyenne et la médiane ;
2. le premier et le troisième quartile ;
3. la variance empirique, l'écart-type et l'écart inter-quartile ;
4. tracer la boîte à moustaches.

Question 1 : Taille de l'échantillon : 10.

Moyenne :

$$\bar{X} = \frac{1}{10}(33 + 34 + 26 + \dots + 32) = 38.3$$

Médiane. On trie le tableau : $X' = (26, 26, 32, 33, 34, 43, 44, 47, 49, 49)$. Comme on a un nombre pair d'observations, la médiane est égale à la moyenne des deux valeurs centrales :

$$m = \frac{1}{2}(34 + 43) = 38.5.$$

Question 2 : Premier quartile (utilisation de la formule du cours avec $p = 1/4$) :

$$\hat{Q}_1 = 32 \times \left(3 - \frac{9}{4}\right) + 33 \times \left(\frac{9}{4} - 3 + 1\right) = 32.25.$$

Troisième quartile (formule du cours avec $p = 3/4$) :

$$\hat{Q}_3 = 44 \times \left(7 - \frac{27}{4}\right) + 47 \times \left(\frac{27}{4} - 7 + 1\right) = 46.25.$$


Question 3 : Variance empirique : $\tilde{\sigma}^2 = 74.81$.

Note (si un étudiant demande) : calcul fait sans la correction de Bessel.

Écart-type : $\tilde{\sigma} = 8.65$.

Écart inter-quartile : $EI := \hat{Q}_3 - \hat{Q}_1 = 14$.

Question 4 : Boîte à moustaches :



Exercice 2

On représente dans le tableau suivant les notes d'élèves à un examen.

élève	note	élève	note	élève	note	élève	note
R. D.	15	F. Z.	11	M. A.	8	I. E.	17
F. B.	14	C. M.	13	D. D.	7	G. L.	14
S. M.	12	N. S.	14	T. K.	12	C. B.	10
A. T.	11	H. V.	17	L. H.	7	V. L.	11
R. J.	13	V. S.	16	G. L.	10	L. L.	10
S. G.	13	P. Z.	16	H. F.	4	B. D.	15

Tracer le tableau des effectifs.

Réponse :

note	effectif
4	1
7	2
8	1
10	3
11	3
12	2
13	3
14	3
15	2
16	2
17	2

Exercice 3

On s'intéresse aux salaires des employés d'une entreprise. Le tableau de données initial, contenant le salaire de chaque employé, a déjà été traité pour obtenir le tableau des effectifs suivant, indiquant les salaires, et le nombre d'employés qui touche chaque salaire (pour des raisons de lisibilité, ce tableau a été découpé en trois) :

salaire	employés	salaire	employés	salaire	employés
1300	7	1900	3	2500	12
1400	74	2000	4	2600	9
1500	134	2100	11	2700	1
1600	60	2200	17	2800	2
1700	14	2300	16	3000	1
1800	2	2400	22	3200	1

Questions sur l'analyse de données

1. Donner le nombre d'employés dans l'entreprise, le salaire minimum et le salaire maximum. Donner également les modalités des salaires.
2. Calculer la moyenne, la médiane et le mode des salaires.
3. Montrer que la variance empirique des salaires peut s'écrire :

$$\tilde{\sigma}^2 = \frac{\sum_{i=1}^C n_i (s_i - \bar{X})^2}{\sum_{i=1}^C n_i},$$

où C est le nombre de salaires différents, les $s_1 < s_2 < \dots < s_C$ sont les salaires et, pour tout $1 \leq i \leq C$, n_i est le nombre d'employés touchant le salaire s_i .

4. Calculer la variance empirique et l'écart-type.
5. Calculer le premier quartile, le troisième quartile et l'écart inter-quartile.

6. Tracer l'histogramme des salaires.

7. Commenter l'histogramme. On pourra s'appuyer sur les valeurs calculées pour la moyenne, la médiane, le mode, etc.

Question 1 : Nombre d'employés : $n = 390$. Salaire minimum : 1300. Salaire maximum : 3200. Modalités : $\{1300, 1400, 1500, \dots, 2700, 2800, 3000, 3200\}$.

Question 2 : Moyenne : $\bar{X} = 1715$. Médiane : $m = 1500$. Mode : 1500.

Question 3 : On a :

$$\begin{aligned}\tilde{\sigma}^2 &= \frac{1}{n} \sum_{i=1}^n (X_i - \bar{X})^2 \\ &= \frac{1}{n} \sum_{j=1}^C \sum_{i=1}^{n_j} (s_j - \bar{X})^2 \\ &= \frac{1}{n} \sum_{j=1}^C n_j (s_j - \bar{X})^2.\end{aligned}$$

En remplaçant l'effectif total n par la somme des effectifs $\sum_{j=1}^C n_j$, on aboutit au résultat.

Question 4 : Variance : $\tilde{\sigma}^2 = 151369$, écart-type : $\tilde{\sigma} = 389$.


Question 5 : On a :

$$\hat{Q}_1 = 1500.0$$

$$\hat{Q}_3 = 1900.0$$

$$EI = 400.0.$$

Question 6 : Histogramme :



Question 7 : On remarque que l’histogramme contient deux “bosses”, ou modes. Le premier contient beaucoup plus d’effectifs que le second. À cause de cela, la médiane, les quartiles et la moyenne ne permettent pas de rendre compte de la deuxième bosse.

Plus généralement, il est très difficile de mettre en valeur le caractère multimodal d’une série de données seulement à l’aide de la moyenne, la médiane, les quartiles, etc. Il est souvent nécessaire de tracer un graphique pour cela.

Questions sur le traitement des données

1. Ce tableau a été obtenu par traitement d’un tableau de données initial, contenant le salaire de chaque employé.
À quoi ressemblait le tableau initial ? Tracer un exemple pour ce tableau, en indiquant les *variables* et la nature de chaque *observation*.
2. Les valeurs de salaires vous semblent-elles crédibles ? Indiquer quelle opération de pré-traitement elles ont pu subir.
3. Cette opération de pré-traitement est-elle susceptible de changer les résultats de l’analyse de données ? Si oui, dans quelle mesure ?

Question 1 : Il s’agit d’un tableau de ce type :

nom de l’employé	salaire
...	1400
...	1500
...	2200
...	2800
⋮	⋮

Question 2 : Les salaires sont rarement des chiffres “ronds”. Il est probable que les véritables salaires aient été au préalable arrondis à la centaine la plus proche : 1786 → 1800, 1345 → 1300, etc.

Question 3 : Pour le calcul de la moyenne : l’erreur commise dans le calcul est maximale lorsque tous les salariés gagnent des salaires qui se terminent, par exemple, par 50 (1750, 2250, etc.). Dans ce cas, après arrondi (à la centaine inférieure), la moyenne sera sous-estimée de 49.

Pour le calcul de la médiane : si, après arrondi, la médiane est de 1500, cela signifie que, avant arrondi, les deux valeurs centrales se situent entre 1451 et 1550. Dans la pire situation, ces deux valeurs sont égales à 1550, et on sous-estime la médiane de 50.

Donc, si l’on s’autorise une erreur de 50, dans ces calculs, le pré-traitement des données ne change pas fondamentalement les résultats de notre analyse.


Exercice 4

On considère une population de ménages, classée en fonction de leur nombre de parts fiscales :

nombre de parts	1	1.5	2	2.5	3	3.5	4	4.5
nombre de ménages	48	58	136	184	210	122	62	12

1. Proposer une représentation graphique de ce tableau.
2. Tracer le tableau de fréquences.
3. Tracer le tableau de fréquences cumulées ainsi que la représentation graphique correspondante.
4. En déduire une approximation de la médiane, du premier quartile et du troisième quartile.

Question 1 : Histogramme (adapté pour représenter un tableau d'effectifs) :




Question 2 : Tableau de fréquences :

nombre de parts	1	1.5	2	2.5	3	3.5	4	4.5
proportion de ménages	5.8%	7.0%	16.3%	22.1%	25.2%	14.7%	7.5%	1.4%

Question 3 : Tableau de fréquences cumulées :

nombre de parts	1	1.5	2	2.5	3	3.5	4	4.5
proportion de ménages	5.8%	12.7%	29.1%	51.2%	76.4%	91.1%	98.6%	100%

Histogramme (adapté pour représenter un tableau de fréquences cumulées) :



Question 4 : Voir graphique précédent.


Exercice 5

On dispose des résultats de campagnes publicitaires effectuées sur l'un des médias suivants : la radio et les journaux. Pour les 9 campagnes effectuées à la radio, les ventes ont atteint les valeurs suivantes : $X_1 = (2.6, 5.3, 5.7, 7.6, 8.4, 8.8, 9.5, 10.8, 10.9)$. Dans le cas des campagnes effectuées dans les journaux, les ventes ont été de $X_2 = (5.3, 5.6, 6.6, 6.7, 7.2, 7.3, 8.5, 9.2, 10.4)$. On cherche à comparer l'efficacité des deux types de campagnes publicitaires.

1. Tracer côte à côte et sur une même échelle les diagrammes à moustaches des deux séries de données.
2. Commenter le graphique ainsi obtenu et conclure.

Question 1 : Il faut d'abord calculer $\hat{Q}_1$, $\hat{Q}_3$ et la médiane m . Pour les journaux : $\hat{Q}_1 = 6.6$, $\hat{Q}_3 = 8.5$, $m = 7.2$. Pour la radio : $\hat{Q}_1 = 5.7$, $\hat{Q}_3 = 9.5$, $m = 8.4$.

Note : comme chaque série comporte 9 valeurs, il est très facile de calculer les quartiles : les calculs des quartiles tombent "juste".



Question 2 : La médiane des ventes après une campagne publicitaire à la radio est plus élevée que pour les journaux. On pourrait penser qu'une campagne faite à la radio est plus efficace.

Mais on observe que l'écart inter-quartile pour la radio est beaucoup plus large que pour les journaux. Aussi, pour la radio, le premier quartile et la valeur minimale sont plus faibles que pour les journaux. Par conséquent, les campagnes faites à la radio risquent d'échouer plus gravement que dans les journaux.