

TD d'analyse de données n°2

L3 MIAE (Informatique) S1, Université Paris Dauphine – PSL

Rappels

Soit un tableau de données à deux variables X et Y et contenant n observations (X_i, Y_i) .

- Le nuage de points de (X, Y) est le graphe sur lequel sont représentés les n points (X_i, Y_i) , pour $i \in \{1, \dots, n\}$.
- La covariance de (X, Y) est définie par :

$$\text{Cov}(X, Y) = \frac{1}{n} \sum_{i=1}^n (X_i - \bar{X})(Y_i - \bar{Y}),$$

où $\bar{X}$ et $\bar{Y}$ sont respectivement la moyenne de X et la moyenne de Y .

- La corrélation (ou corrélation de Pearson) de (X, Y) est définie par :

$$\text{corr}(X, Y) = \frac{\text{Cov}(X, Y)}{\sigma_X \sigma_Y},$$

où σ_X et σ_Y sont respectivement l'écart-type de X et l'écart-type de Y .

- Lorsqu'un tableau de données représente des variables $X^{(1)}, X^{(2)}, X^{(3)}, \dots$, le tableau de corrélations correspondant est un tableau à double entrée qui contient, dans la case située ligne i , colonne j : $\text{corr}(X^{(i)}, X^{(j)})$.

Par exemple :

	X	Y	Z
X	$\text{corr}(X, X)$	$\text{corr}(X, Y)$	$\text{corr}(X, Z)$
Y	$\text{corr}(Y, X)$	$\text{corr}(Y, Y)$	$\text{corr}(Y, Z)$
Z	$\text{corr}(Z, X)$	$\text{corr}(Z, Y)$	$\text{corr}(Z, Z)$

Puisque la corrélation est symétrique ($\text{corr}(Y, X) = \text{corr}(X, Y)$), alors le tableau de corrélations est symétrique par rapport à la diagonale. Puisque $\text{corr}(X, X) = 1$, alors la diagonale du tableau ne contient que des 1.

- La corrélation de Spearman de (X, Y) est définie par :

$$r_s(X, Y) = \text{corr}(r_X, r_Y),$$

où r_X le rang des valeurs présentes dans la série de données de X : si $X = (3, 2, 5, 4, 1, 4)$, alors $r_X = (3, 2, 6, 4.5, 1, 4.5)$. Si deux valeurs (ou plus) sont égales,

alors on leur attribue un rang égal à la moyenne des rangs qu'elles auraient si elles étaient différentes. Dans l'exemple ci-dessus, la valeur 4 apparaît deux fois et devrait occuper les rangs 4 et 5, on fixe donc son rang à $\frac{1}{2}(4 + 5)$. Il en va de même pour r_Y et Y .

Exercice 1 : calcul d'une corrélation


Soit un tableau de données :

X	6	14	9	11	12	10	5	12
Y	7	1	2	6	3	10	8	4

Analyse de corrélation.

1. Tracer le nuage de points (X, Y) .
2. Calculer la moyenne, la variance et l'écart-type de X et de Y .
3. Calculer la covariance et la corrélation de (X, Y) .
4. X et Y sont-elles corrélées positivement ? négativement ? non corrélées ? Justifier.
5. Pouvait-on prédire la réponse à la question précédente en observant le nuage de points tracé en question 1 ?

Question 1 :



Question 2 :

- $\bar{X} = 9.88, \bar{Y} = 5.12$;
- variances : $\sigma_X^2 = 8.36, \sigma_Y^2 = 8.61$;
- écarts-types : $\sigma_X = 2.89, \sigma_Y = 2.93$.

Question 3 : $\text{Cov}(X, Y) = -5.1, \text{corr}(X, Y) = -0.6$.

Question 4 : Comme $\text{corr}(X, Y) = -0.6 < 0$, alors X et Y sont corrélées négativement.

Question 5 : Oui, on pouvait le prédire : le nuage de points indique que les grandes valeurs de X correspondent à de petites valeurs de Y , ce qui est le signe d'une corrélation négative.

Centrage et réduction (facultatif).

1. On note σ_X^2 la variance empirique de X et σ_Y^2 la variance empirique de Y . Soient $X' = \frac{X - \bar{X}}{\sigma_X}$ et $Y' = \frac{Y - \bar{Y}}{\sigma_Y}$.
Calculer la corrélation de (X', Y') . Comparer avec la corrélation de (X, Y) .
2. Cas général : soit un tableau de données à deux variables (X, Y) avec n observations (X_i, Y_i) . On note $\bar{X}$ et $\bar{Y}$ les moyennes de X et Y , et σ_X^2 et σ_Y^2 les variances empiriques de X et Y . Soient $X' = \frac{X - \bar{X}}{\sigma_X}$ et $Y' = \frac{Y - \bar{Y}}{\sigma_Y}$.
Démontrer que $\text{corr}(X, Y) = \text{corr}(X', Y')$.

Question 1 : $\text{corr}(X', Y') = -0.6$.

Question 2 : On a :

$$\begin{aligned}\bar{X}' &= \frac{1}{n} \sum_{i=1}^n X'_i \\ &= \frac{1}{n} \sum_{i=1}^n \frac{X_i - \bar{X}}{\sigma_X} = \frac{1}{\sigma_X} \frac{1}{n} \sum_{i=1}^n X_i - \frac{1}{\sigma_X} \frac{1}{n} \sum_{i=1}^n \bar{X} \\ &= \frac{\bar{X}}{\sigma_X} - \frac{\bar{X}}{\sigma_X} = 0.\end{aligned}$$

De la même façon, $\bar{Y}' = 0$.

On a aussi :

$$\begin{aligned}\sigma_{X'}^2 &= \frac{1}{n} \sum_{i=1}^n (X'_i - \bar{X}')^2 = \frac{1}{n} \sum_{i=1}^n (X'_i)^2 \\ &= \frac{1}{n} \sum_{i=1}^n \left(\frac{X_i - \bar{X}}{\sigma_X} \right)^2 = \frac{1}{\sigma_X^2} \frac{1}{n} \sum_{i=1}^n (X_i - \bar{X})^2 \\ &= \frac{1}{\sigma_X^2} \sigma_X^2 = 1.\end{aligned}$$

De la même façon, $\sigma_{Y'}^2 = 1$.

On peut calculer la covariance :

$$\text{Cov}(X', Y') = \text{Cov} \left(\frac{X - \bar{X}}{\sigma_X}, \frac{Y - \bar{Y}}{\sigma_Y} \right) = \frac{1}{\sigma_X \sigma_Y} \text{Cov}(X, Y) = \text{corr}(X, Y).$$

Enfin :

$$\text{corr}(X', Y') = \frac{\text{Cov}(X', Y')}{\sigma_{X'} \sigma_{Y'}} = \text{Cov}(X', Y') = \text{corr}(X, Y).$$

Exercice 2 : tableau de corrélations

On reprend les variables X et Y de l'exercice 1, et on ajoute la variable Z :


X	6	14	9	11	12	10	5	12
Y	7	1	2	6	3	10	8	4
Z	7	8	8	2	23	0	1	0

1. Tracer le tableau de corrélation associé. Indiquer le type de corrélation (positive, négative, non corrélée) de chaque paire de variables (X, Y) , (X, Z) et (Y, Z) .
2. Tracer le nuage de points (X, Z) . Quelle observation semble aberrante ?
3. Recalculer la corrélation de (X, Z) après l'avoir supprimée du tableau de données. Conclure.

Question 1 :

	X	Y	Z
X	1.00	-0.60	0.27
Y	-0.60	1.00	-0.53
Z	0.27	-0.53	1.00

Question 2 :



L'observation n°5, $(12, 3, 23)$ est éloignée des autres. Il semble que, en la supprimant, le nuage de points ne montre aucune corrélation.

Question 3 : Après suppression de la valeur aberrante, la corrélation de (X, Z) est : 0.06.

Exercice 3 : corrélation de Spearman

Les notes de 8 élèves dans deux disciplines X et Y ont été compilées dans le tableau suivant :

X	6	8	9	9.5	10	11	15	18
Y	8	12.5	9	12.5	13	13	14	20

1. Calculer la corrélation de Spearman de (X, Y) .
Interpréter le résultat.
2. Calculer la corrélation (de Pearson) de (X, Y) .
Comparer avec la corrélation de Spearman.

Question 1 : Tableau des rangs :

r_X	1	2	3	4	5	6	7	8
r_Y	1	3.5	2	3.5	5.5	5.5	7	8

Corrélation de Spearman :

$$r_s = \frac{\text{Cov}(r_X, r_Y)}{\sigma_{r_X} \sigma_{r_Y}} = 0.952.$$

La corrélation de Spearman est la corrélation entre les rangs obtenus par les élèves dans deux disciplines différentes. Les rangs sont fortement corrélés (positivement).

Question 2 : Corrélation (de Pearson) :

$$\text{corr}(X, Y) = 0.895 < 0.952 = r_s.$$

La corrélation de Pearson est plus faible que la corrélation de Spearman.