

TD d'analyse de données n°3

L3 MIAE (Informatique) S1, Université Paris Dauphine – PSL

Exercice 1 : régression linéaire simple

Soit le tableau de données suivant :

X	4	1	-1	-3	0	-4	5	-2
Y	4	-3	3	-4	3	-7	6	-2

1. Tracer le nuage de points (X, Y) . On se servira du même graphique pour tracer des éléments supplémentaires.
2. On va effectuer une régression linéaire avec X comme *variable explicative* et Y comme *variable expliquée*. Définir le rôle de chacune des variables.
3. Calculer $\text{corr}(X, Y)$.
Si l'on trace la droite de la régression linéaire ayant X comme variable explicative et Y comme variable expliquée, quel serait le signe de sa pente ? Justifier.
4. On effectue la régression linéaire avec le modèle suivant : $Y = \beta_1 X$.
On cherche à minimiser la Somme des Carrés des Résidus en fonction de β_1 définie par :

$$\text{SCR}(\beta_1) = \sum_{i=1}^n (Y_i - \beta_1 X_i)^2.$$

Calculer le paramètre $\hat{\beta}_1$ minimisant la SCR. Exprimer $\hat{\beta}_1$ à l'aide de variances/covariances.

5. Tracer la droite de régression associée, d'équation $y = \beta_1 x$ sur le même graphique qu'à la question 1.

Exercice 2 : correction de Bessel

On considère une suite de variables aléatoires $X = (X_1, \dots, X_n)$ indépendantes identiquement distribuées.

1. Rappeler la formule de la variance empirique.

2. On rappelle que l'estimateur de la variance de X avec correction de Bessel est :

$$\bar{\sigma}^2 = \frac{1}{n-1} \sum_{i=1}^n (X_i - \bar{X})^2.$$

Calculer $\mathbb{E}[\bar{\sigma}^2]$ en fonction de $\text{Var}(X)$.

3. Si l'on veut estimer la variance d'une série de données, est-il plus fiable d'utiliser la correction de Bessel ou la variance empirique ?