

TD d'analyse de données n°3

L3 MIAE (Informatique) S1, Université Paris Dauphine – PSL

Exercice 1 : régression linéaire simple

Soit le tableau de données suivant :

X	4	1	-1	-3	0	-4	5	-2
Y	4	-3	3	-4	3	-7	6	-2

1. Tracer le nuage de points (X, Y) . On se servira du même graphique pour tracer des éléments supplémentaires.
2. On va effectuer une régression linéaire avec X comme *variable explicative* et Y comme *variable expliquée*. Définir le rôle de chacune des variables.
3. Calculer $\text{corr}(X, Y)$.
Si l'on trace la droite de la régression linéaire ayant X comme variable explicative et Y comme variable expliquée, quel serait le signe de sa pente ? Justifier.
4. On effectue la régression linéaire avec le modèle suivant : $Y = \beta_1 X$.
On cherche à minimiser la Somme des Carrés des Résidus en fonction de β_1 définie par :


$$\text{SCR}(\beta_1) = \sum_{i=1}^n (Y_i - \beta_1 X_i)^2.$$

Calculer le paramètre $\hat{\beta}_1$ minimisant la SCR. Exprimer $\hat{\beta}_1$ à l'aide de variances/covariances.

5. Tracer la droite de régression associée, d'équation $y = \beta_1 x$ sur le même graphique qu'à la question 1.

Correction.

1. Graphique :



2. Lorsqu'on effectue une régression linéaire, on cherche à exprimer une variable *expliquée* à l'aide de variables *explicatives*.
3. $\text{corr}(X, Y) \approx 0.814 > 0$, donc la pente de la droite de régression est positive.
4. On développe la SCR :

$$\text{SCR}(\beta_1) = \sum_{i=1}^n (y_i^2 + \beta_1^2 x_i^2 - 2\beta_1 x_i y_i) = \sum_{i=1}^n x_i^2 - 2\beta_1 \sum_{i=1}^n x_i y_i + \beta_1^2 \sum_{i=1}^n x_i^2.$$

On dérive la SCR par rapport à β_1 :

$$\text{SCR}'(\beta_1) = -2 \sum_{i=1}^n x_i y_i + 2\beta_1 \sum_{i=1}^n x_i^2.$$

La dérivée s'annule pour $\beta_1 = \frac{\sum_{i=1}^n x_i y_i}{\sum_{i=1}^n x_i^2}$.

Comme cette fonction est convexe (on peut calculer la dérivée seconde et vérifier qu'elle est positive pour s'en convaincre), alors son minimum est atteint pour $\beta_1 = \frac{\sum_{i=1}^n x_i y_i}{\sum_{i=1}^n x_i^2}$.

Puisque $\bar{x} = 0$ et $\bar{y} = 0$, alors $\overline{\text{Cov}}(X, Y) = \frac{1}{n} \sum_{i=1}^n x_i y_i$ et $\bar{\sigma}_X^2 = \frac{1}{n} \sum_{i=1}^n x_i^2$. Donc :

$$\beta_1 = \frac{\overline{\text{Cov}}(X, Y)}{\bar{\sigma}_X^2}.$$

Numériquement : $\hat{\beta}_1 = 1.17$.

5. Voir graphique.

Exercice 2 : correction de Bessel

On considère une suite de variables aléatoires $X = (X_1, \dots, X_n)$ indépendantes identiquement distribuées.

1. Rappeler la formule de la variance empirique.
2. On rappelle que l'estimateur de la variance de X avec correction de Bessel est :

$$\bar{\sigma}^2 = \frac{1}{n-1} \sum_{i=1}^n (X_i - \bar{X})^2.$$

Calculer $\mathbb{E}[\bar{\sigma}^2]$ en fonction de $\text{Var}(X)$.

3. Si l'on veut estimer la variance d'une série de données, est-il plus fiable d'utiliser la correction de Bessel ou la variance empirique ?

Correction.

1. variance empirique : $\frac{1}{n} \sum_{i=1}^n (X_i - \bar{X})^2$.
2. **Remarque :** L'espérance est linéaire, ce qui signifie que, pour tout α et pour tout couple de variables aléatoires (X, Y) , on a : $\mathbb{E}[\alpha X + Y] = \alpha \mathbb{E}[X] + \mathbb{E}[Y]$.
Lorsque X et Y sont indépendantes, on a : $\mathbb{E}[XY] = \mathbb{E}[X]\mathbb{E}[Y]$.
Mais, en règle générale, ce n'est pas le cas : $\mathbb{E}[XY] \neq \mathbb{E}[X]\mathbb{E}[Y]$. On ne peut donc pas écrire $\mathbb{E}[X_i \bar{X}] = \mathbb{E}[X_i]\mathbb{E}[\bar{X}]$. En particulier, il est vraisemblable que X_i et $\bar{X}$ ne soient pas indépendantes, puisqu'on utilise les X_i pour calculer $\bar{X}$.

On a :

$$\begin{aligned}\mathbb{E}[\bar{\sigma}^2] &= \mathbb{E} \left[\frac{1}{n-1} \sum_{i=1}^n (X_i - \bar{X})^2 \right] \\ &= \frac{1}{n-1} \sum_{i=1}^n \mathbb{E} [(X_i - \bar{X})^2] \quad (\text{linéarité de l'espérance})\end{aligned}$$

Or :

$$\mathbb{E} [(X_i - \bar{X})^2] = \mathbb{E} [X_i^2 - 2X_i \bar{X} + \bar{X}^2] = \mathbb{E}[X_i^2] - 2\mathbb{E}[X_i \bar{X}] + \mathbb{E}[\bar{X}^2].$$

Donc :

$$\begin{aligned}\mathbb{E}[\bar{\sigma}^2] &= \frac{1}{n-1} \sum_{i=1}^n (\mathbb{E}[X_i^2] - 2\mathbb{E}[X_i \bar{X}] + \mathbb{E}[\bar{X}^2]) \\ &= \frac{1}{n-1} \left(\sum_{i=1}^n \mathbb{E}[X_i^2] - 2 \sum_{i=1}^n \mathbb{E}[X_i \bar{X}] + \sum_{i=1}^n \mathbb{E}[\bar{X}^2] \right)\end{aligned}$$

Premier terme : comme les X_i sont identiquement distribuées, alors $\mathbb{E}[X_1^2] = \mathbb{E}[X_2^2] = \dots = \mathbb{E}[X_n^2]$. Donc $\mathbb{E}[X_i^2] = \mathbb{E}[X_1^2]$, et $\sum_{i=1}^n \mathbb{E}[X_i^2] = \sum_{i=1}^n \mathbb{E}[X_1^2] = n\mathbb{E}[X_1^2]$.

Deuxième terme : par linéarité de l'espérance, $\sum_{i=1}^n \mathbb{E}[X_i \bar{X}] = \mathbb{E}[(\sum_{i=1}^n X_i) \bar{X}]$. Or $\sum_{i=1}^n X_i = n\bar{X}$, donc $\sum_{i=1}^n \mathbb{E}[X_i \bar{X}] = n\mathbb{E}[\bar{X}^2]$.

Troisième terme : $\sum_{i=1}^n \mathbb{E}[\bar{X}^2] = n\mathbb{E}[\bar{X}^2]$.

En regroupant les termes, on a :

$$\mathbb{E}[\bar{\sigma}^2] = \frac{1}{n-1} (n\mathbb{E}[X_1^2] - 2n\mathbb{E}[\bar{X}^2] + n\mathbb{E}[\bar{X}^2]) = \frac{n}{n-1} (\mathbb{E}[X_1^2] - \mathbb{E}[\bar{X}^2]).$$

Il reste maintenant à calculer :

$$\begin{aligned}
\mathbb{E}[\bar{X}^2] &= \mathbb{E}\left[\left(\frac{1}{n} \sum_{i=1}^n X_i\right)^2\right] = \mathbb{E}\left[\frac{1}{n^2} \left(\sum_{i=1}^n X_i\right)^2\right] \\
&= \mathbb{E}\left[\frac{1}{n^2} \left(\sum_{i=1}^n X_i\right) \left(\sum_{i=1}^n X_i\right)\right] \\
&= \mathbb{E}\left[\frac{1}{n^2} \sum_{i=1}^n \sum_{j=1}^n X_i X_j\right] \\
&= \frac{1}{n^2} \sum_{i=1}^n \sum_{j=1}^n \mathbb{E}[X_i X_j] \quad (\text{linéarité de l'espérance}).
\end{aligned}$$

Or $\mathbb{E}[X_i X_j]$ peut prendre deux valeurs :

- si $j = i$, alors $\mathbb{E}[X_i X_j] = \mathbb{E}[X_i X_i] = \mathbb{E}[X_i^2] = \mathbb{E}[X_1^2]$.
- si $j \neq i$, alors X_i et X_j sont indépendantes, donc : $\mathbb{E}[X_i X_j] = \mathbb{E}[X_i] \mathbb{E}[X_j] = \mathbb{E}[X_1] \mathbb{E}[X_1] = \mathbb{E}[X_1]^2$.

Donc :

$$\begin{aligned}
\mathbb{E}[\bar{X}^2] &= \frac{1}{n^2} \left(\sum_{i=1}^n \left[\mathbb{E}[X_i X_i] + \sum_{j \neq i} \mathbb{E}[X_i X_j] \right] \right) \\
&= \frac{1}{n^2} \left(\sum_{i=1}^n [\mathbb{E}[X_1^2] + (n-1)\mathbb{E}[X_1]^2] \right) \\
&= \frac{1}{n^2} (n\mathbb{E}[X_1^2] + n(n-1)\mathbb{E}[X_1]^2) \\
&= \frac{1}{n} (\mathbb{E}[X_1^2] + (n-1)\mathbb{E}[X_1]^2).
\end{aligned}$$

Finalement :

$$\begin{aligned}
\mathbb{E}[\bar{\sigma}^2] &= \frac{n}{n-1} \left(\mathbb{E}[X_1^2] - \frac{1}{n} (\mathbb{E}[X_1^2] + (n-1)\mathbb{E}[X_1]^2) \right) \\
&= \frac{n}{n-1} \left(\left(1 - \frac{1}{n}\right) \mathbb{E}[X_1^2] - \frac{n-1}{n} \mathbb{E}[X_1]^2 \right) \\
&= \frac{1}{n-1} ((n-1)\mathbb{E}[X_1^2] - (n-1)\mathbb{E}[X_1]^2) \\
&= \mathbb{E}[X_1^2] - \mathbb{E}[X_1]^2 \\
&= \text{Var}(X_1) = \text{Var}(X).
\end{aligned}$$

3. Comme $\mathbb{E}[\bar{\sigma}^2] = \text{Var}(X)$, alors $\bar{\sigma}^2$ est un estimateur non biaisé de $\text{Var}(X)$. Par linéarité de l'espérance, l'espérance de la variance empirique est : $\mathbb{E}\overline{\text{Var}}(X) = \frac{n-1}{n} \mathbb{E}\bar{\sigma}^2 = \frac{n-1}{n} \text{Var}(X)$. La variance empirique a donc tendance à sous-estimer la véritable variance, elle est biaisée.