

TD d'analyse de données n°4

L3 MIAE (Informatique) S1, Université Paris Dauphine – PSL

Exercice 1 : régressions linéaires $Y = f(X)$ et $X = f(Y)$


Soit le tableau de données suivant :

X	4	1	-1	-2	0	-4	5	-2
Y	13	6	12	5	12	2	15	8

1. Tracer le nuage de points (X, Y) . On se servira du même graphique pour tracer des éléments supplémentaires.
2. On effectue la régression linéaire avec le modèle suivant : $Y = \beta_0 + \beta_1 X$.
Rappeler la définition de la somme des carrés des résidus (SCR).
Calculer les paramètres $\hat{\beta}_0$ et $\hat{\beta}_1$ minimisant la SCR.
3. Tracer la droite de régression associée.

Correction.

1. Graphique :



2. On a :

$$\text{SCR}(\beta_0, \beta_1) = \sum_{i=1}^n (Y_i - \beta_0 - \beta_1 X_i)^2 = \sum_{i=1}^n e_i^2,$$

où les $e_i := Y_i - \beta_0 - \beta_1 X_i$ sont les résidus.

On a :

$$\hat{\beta}_0 = 8.98$$

$$\hat{\beta}_1 = 1.16.$$

3. Voir graphique.

Régression $X = f(Y)$. On souhaite comparer la droite de régression obtenue lorsqu'on cherche à expliquer Y en fonction de X (questions précédentes), avec celle qu'on obtient lorsqu'on explique X en fonction de Y .

1. On considère le modèle $X = \beta'_0 + \beta'_1 Y$.
Prédire le signe de la pente de la droite de régression sans effectuer de calcul supplémentaire.
2. Effectuer la régression linéaire dans ce cas et tracer la droite de régression obtenue. Comparer les deux droites de régression. Sont-elles identiques ?

Correction.

1. La pente de la droite de régression est du même signe que $\text{corr}(Y, X) = \text{corr}(X, Y) > 0$ (par symétrie de la corrélation), donc la pente est encore positive.

On a :

$$\hat{\beta}'_0 = -4.78$$

$$\hat{\beta}'_1 = 0.54.$$

2. Voir graphique. Les deux droites de régression ne sont pas identiques. Cela était prévisible, puisque les problèmes consistant à estimer les Y_i à partir des X_i et les X_i à partir des Y_i sont des problèmes différents.

Exercice 2 : pré-traitement des variables

Des données sur la valeur ajoutée annuelle et le nombre de salariés ont été récoltées sur un grand nombre d'entreprises. On souhaite pouvoir prédire la valeur ajoutée annuelle d'une entreprise (en millions d'euros, variable notée Y) en fonction de son nombre de salariés (variable notée X).

Pour des raisons de simplicité, on s'intéresse ici à un échantillon représentatif d'entreprises :

X	184	91	426	46	4	13	7642
Y	9.25	3.66	28.8	2.89	0.273	2.24	480

Questions.

1. Expliquer pourquoi il n'est pas pertinent d'effectuer une régression linéaire directement sur ce tableau de données. On pourra essayer de tracer le nuage de points.
2. Proposer une transformation du tableau de données. On notera $\tilde{X}$ et $\tilde{Y}$ les nouvelles variables. Tracer le tableau des données transformées.

- Effectuer la régression linéaire permettant de prédire $\tilde{Y}$ en fonction de $\tilde{X}$. Tracer le nuage de points $(\tilde{X}, \tilde{Y})$ ainsi que la droite de régression.
- À partir de la régression linéaire obtenue dans la question précédente, proposer une relation permettant de prédire Y à partir de X .


Correction.

- Les valeurs dans chaque série de données sont étalées sur plusieurs ordres de grandeur, situation peu adaptée à une régression linéaire simple.
- On peut effectuer une transformation logarithmique du tableau de données : $\tilde{X}_i = \log(X_i)$ et $\tilde{Y}_i = \log(Y_i)$.

$\tilde{X}$	5.21	4.51	6.05	3.83	1.39	2.56	8.94
$\tilde{Y}$	2.22	1.3	3.36	1.06	-1.3	0.805	6.17

- Pour le modèle $\hat{Y}_i = \beta_0 + \beta_1 X_i$, les valeurs optimales de (β_0, β_1) sont :

$$\hat{\beta}_0 = -2.4 \qquad \hat{\beta}_1 = 0.94.$$



- Par définition de $\tilde{X}$ et $\tilde{Y}$, on a :

$$\begin{aligned} \tilde{Y}_i &= \beta_0 + \beta_1 \tilde{X}_i \\ \Leftrightarrow \log(Y_i) &= \beta_0 + \beta_1 \log(X_i) \\ \Leftrightarrow Y_i &= \exp(\beta_0) X_i^{\beta_1}. \end{aligned}$$

Numériquement, on a : $Y_i = 0.091 \cdot X_i^{0.94}$, ce qui n'est finalement pas éloigné d'une relation linéaire ($0.94 \approx 1$).

Exercice 3 : Évaluation de l'incertitude sur les paramètres

On reprend le tableau de données de l'exercice 1 :

X	4	1	-1	-2	0	-4	5	-2
Y	13	6	12	5	12	2	15	8

On considère que les valeurs Y_i ont été générées de la façon suivante :

$$Y_i = \beta_0 + \beta_1 X_i + \epsilon_i,$$

où les variables aléatoires $(\epsilon_1, \dots, \epsilon_n)$ sont centrées, de même variance σ^2 et de covariance nulle ($\forall i \neq j, \text{Cov}(\epsilon_i, \epsilon_j) = 0$).

Questions.

1. Estimer σ .
2. En déduire une estimation de $\text{MSE}(\hat{\beta}_0)$ et de $\text{MSE}(\hat{\beta}_1)$.
3. Calculer $\sqrt{\text{MSE}(\hat{\beta}_0)}$ et $\sqrt{\text{MSE}(\hat{\beta}_1)}$, et comparer avec les valeurs obtenues pour $\hat{\beta}_0$ et $\hat{\beta}_1$.
4. Calculer le coefficient R^2 de la régression linéaire.

Correction.

1. Un estimateur de σ est :

$$\hat{\sigma} = \sqrt{\frac{1}{n-2} \sum_{i=1}^n (Y_i - \hat{Y}_i)^2}.$$

On a donc : $\hat{\sigma} = 3.01$.

2. On rappelle que :

$$\text{MSE}(\hat{\beta}_0) = \sigma^2 \left(\frac{1}{n} + \frac{\bar{x}^2}{\sum_{i=1}^n (x_i - \bar{x})^2} \right) \quad \text{MSE}(\hat{\beta}_1) = \frac{\sigma^2}{\sum_{i=1}^n (x_i - \bar{x})^2}.$$

Donc, en remplaçant σ par $\hat{\sigma}$: $\text{MSE}(\hat{\beta}_0) = 1.13$, $\text{MSE}(\hat{\beta}_1) = 0.14$.

3. On a : $\sqrt{\text{MSE}(\hat{\beta}_0)} = 1.06$ et $\sqrt{\text{MSE}(\hat{\beta}_1)} = 0.37$.

L'amplitude de variation de $\hat{\beta}_0$ est de l'ordre de 1.06, ce qui est bien inférieur à la valeur de $\hat{\beta}_0 = 8.98$. Il en est de même avec $\hat{\beta}_1$, donc l'amplitude de variation est de l'ordre de 0.37, bien inférieur à $\hat{\beta}_1 = 1.16$.

Qualitativement, les valeurs trouvées pour $\hat{\beta}_0$ et $\hat{\beta}_1$ sont donc relativement fiables.

4. On a :

$$R^2 = 1 - \frac{\text{SCR}(\hat{\beta}_0, \hat{\beta}_1)}{\text{SCT}(\hat{\beta}_0, \hat{\beta}_1)},$$

donc : $R^2 = 0.63$.

Preuves des formules du cours. Dans le cas général :

1. vérifier que $\mathbb{E}\hat{\beta}_0 = \beta_0$ et $\mathbb{E}\hat{\beta}_1 = \beta_1$;
2. démontrer les formules du cours pour $\text{MSE}(\hat{\beta}_0)$ et $\text{MSE}(\hat{\beta}_1)$.

Correction.

1. Calcul de $\mathbb{E}\hat{\beta}_1$:

$$\begin{aligned}\mathbb{E}\hat{\beta}_1 &= \frac{\sum_{i=1}^n (x_i - \bar{x}) \mathbb{E}(Y_i - \bar{Y})}{\sum_{i=1}^n (x_i - \bar{x})^2} = \frac{\sum_{i=1}^n (x_i - \bar{x}) (\mathbb{E}Y_i - \frac{1}{n} \sum_{j=1}^n \mathbb{E}Y_j)}{\sum_{i=1}^n (x_i - \bar{x})^2} \\ &= \frac{\sum_{i=1}^n (x_i - \bar{x}) (\beta_0 + \beta_1 x_i - \frac{1}{n} \sum_{j=1}^n (\beta_0 + \beta_1 x_j))}{\sum_{i=1}^n (x_i - \bar{x})^2} \\ &= \frac{\sum_{i=1}^n (x_i - \bar{x}) (\beta_0 + \beta_1 x_i - \beta_0 - \beta_1 \frac{1}{n} \sum_{j=1}^n x_j)}{\sum_{i=1}^n (x_i - \bar{x})^2} \\ &= \beta_1 \frac{\sum_{i=1}^n (x_i - \bar{x}) (x_i - \bar{x})}{\sum_{i=1}^n (x_i - \bar{x})^2} = \beta_1.\end{aligned}$$

Calcul de $\mathbb{E}\hat{\beta}_0$:

$$\mathbb{E}\hat{\beta}_0 = \mathbb{E}\bar{Y} - \mathbb{E}[\hat{\beta}_1] \bar{x} = \frac{1}{n} \sum_{i=1}^n (\beta_0 + \beta_1 x_i) - \beta_1 \bar{x} = \beta_0 + \beta_1 \bar{x} - \beta_1 \bar{x} = \beta_0.$$

2. Calcul de $\text{MSE}(\hat{\beta}_1)$:

$$\text{MSE}(\hat{\beta}_1) = \text{Var}(\hat{\beta}_1) = \frac{\text{Var} \left(\sum_{i=1}^n (x_i - \bar{x}) (Y_i - \bar{Y}) \right)}{\left(\sum_{i=1}^n (x_i - \bar{x})^2 \right)^2}.$$

En notant $\alpha_i = x_i - \bar{x}$, on a :

$$\begin{aligned}\sum_{i=1}^n (x_i - \bar{x}) (Y_i - \bar{Y}) &= \sum_{i=1}^n \alpha_i (Y_i - \bar{Y}) = \sum_{i=1}^n \alpha_i Y_i - \sum_{i=1}^n \alpha_i \bar{Y} \\ &= \sum_{i=1}^n \alpha_i Y_i - \sum_{i=1}^n \left[\alpha_i \frac{1}{n} \sum_{j=1}^n Y_j \right] = \sum_{i=1}^n \alpha_i Y_i - \sum_{j=1}^n \left[Y_j \sum_{i=1}^n \frac{\alpha_i}{n} \right] \\ &= \sum_{j=1}^n Y_j \left[\alpha_j - \sum_{i=1}^n \frac{\alpha_i}{n} \right] = \sum_{j=1}^n Y_j \alpha_j,\end{aligned}$$

puisque $\sum_{i=1}^n \alpha_i = \sum_{i=1}^n (x_i - \bar{x}) = 0$. Donc, par indépendance des $(Y_i)_i$:

$$\text{Var} \left(\sum_{i=1}^n (x_i - \bar{x}) (Y_i - \bar{Y}) \right) = \sum_{j=1}^n \text{Var}(Y_j) \alpha_j^2 = \sigma^2 \sum_{j=1}^n \alpha_j^2 = \sigma^2 \sum_{i=1}^n (x_i - \bar{x})^2.$$

Finalement :

$$\text{MSE}(\hat{\beta}_1) = \frac{\sigma^2}{\sum_{i=1}^n (x_i - \bar{x})^2}.$$

Calcul de $\text{MSE}(\hat{\beta}_0)$:

$$\begin{aligned}\text{MSE}(\hat{\beta}_0) &= \text{Var}(\hat{\beta}_0) = \text{Var}\left(\bar{Y} - \hat{\beta}_1 \bar{x}\right) = \text{Var}\left(\frac{1}{n} \sum_{i=1}^n Y_i - \bar{x} \frac{\sum_{i=1}^n Y_i \alpha_i}{\sum_{i=1}^n \alpha_i^2}\right) \\ &= \text{Var}\left(\sum_{i=1}^n Y_i \left[\frac{1}{n} - \bar{x} \frac{\alpha_i}{\sum_{j=1}^n \alpha_j^2}\right]\right) = \sigma^2 \sum_{i=1}^n \left(\frac{1}{n} - \bar{x} \frac{\alpha_i}{\sum_{j=1}^n \alpha_j^2}\right)^2 \\ &= \sigma^2 \left(\frac{1}{n} + \bar{x}^2 \frac{\sum_{i=1}^n \alpha_i^2}{(\sum_{j=1}^n \alpha_j^2)^2}\right) = \sigma^2 \left(\frac{1}{n} + \frac{\bar{x}^2}{\sum_{i=1}^n (x_i - \bar{x})^2}\right).\end{aligned}$$

Exercice 4 : Régression linéaire multiple

On effectue une étude sur l'impact des campagnes publicitaires en fonction du média utilisé. Pour ce faire, on dispose du budget dépensé en publicité sur différents médias (*télévision, journaux, radio*), ainsi que de la valeur totale des *ventes* effectuées durant la campagne publicitaire. Pour des raisons de simplicité, on a sélectionné 8 observations, représentatives des 200 observations effectuées. Elles sont compilées dans le tableau de données suivant :

télévision	280.2	59.6	62.3	225.8	56.2	26.8	25.6	121.0
journaux	21.4	43.1	18.3	56.5	29.7	19.3	9.3	48.7
radio	10.1	12.0	12.6	8.2	5.7	33.0	39.0	8.4
ventes	14.8	9.7	9.7	13.4	8.7	8.8	9.5	11.6

Questions.

1. On va résoudre le problème initial en effectuant une régression linéaire. Quelles seront les variables explicatives et les variables expliquées ?
2. Au préalable, on évalue individuellement la relation entre le budget publicitaire dépensé dans les journaux et les ventes. Effectuer la régression linéaire dans ce cas. Quel est le coefficient directeur de la droite de régression ?
3. Maintenant, on effectue la régression linéaire avec les variables explicatives et expliquées définies dans la question 1. Quels sont les coefficients de la régression linéaire ?
4. À l'aide du résultat de la question précédente, classer l'impact du budget dépensé dans chacun des médias sur les ventes totales.
5. Comparer le coefficient associé aux journaux dans le cas de la régression linéaire simple (question 2) et dans le cas de la régression linéaire multiple (question 3). Comment expliquer cette différence ?

Correction.

1. Variables explicatives : télévision, journaux, radio. Variable expliquée : ventes.
2. Régression linéaire simple : $\beta_0 = 9.2607$, $\beta_1 = 0.0492$. Le coefficient directeur est $\beta_1 = 0.05$.

3. Régression linéaire multiple : $\hat{\beta} = (0.0247, 0.0097, 0.0312, 7.331)$.
4. Dans l'ordre décroissant, les dépenses les plus efficaces ont été effectuées : à la radio (coefficient 0.0312), à la télévision (coefficient 0.0247) et dans les journaux (coefficient 0.0097).
5. Le coefficient associé à l'impact de la publicité dans les journaux est significativement plus petit (0.0097) lors de la régression multiple que lors de la régression simple (0.0492). Cette différence provient du fait que les dépenses effectuées pour la publicité à la radio et à la télévision expliquent mieux les ventes observées que les dépenses effectuées pour la publicité dans les journaux. La valeur relativement élevée obtenue lors de la régression simple s'explique par le fait que les dépenses publicitaires effectuées dans les trois médias sont corrélées entre elles.

Exercice 5 : Régression ridge

On considère le tableau de données suivant :

X_1	3	-6	9	8	0	-5	9	1
X_2	0.2	-18.2	12.2	10.3	-6.0	-15.9	11.8	-4.0
Y	1.0	-1.8	2.5	2.5	-0.5	-2.0	3.0	0.5

On souhaite effectuer la régression linéaire de Y en fonction de X_1 et X_2 .

Questions.

1. Effectuer la régression linéaire demandée. Calculer le paramètre $\hat{\beta}$ de la régression ainsi que $\text{SCR}(\hat{\beta})$.
2. Changer la valeur de la variable X_2 dans la quatrième observation : remplacer 10.3 par 10. Puis effectuer à nouveau la régression linéaire et calculer la SCR. La régression linéaire est-elle stable ?
3. Effectuer une régression ridge avec un paramètre de régularisation $\lambda = 0.05$ dans les deux cas précédents. Calculer les paramètres des régressions ainsi que les SCR associées.
4. Comparer les SCR sans et avec régularisation. Comparer les paramètres de la régression sans et avec régularisation. Commenter.

Correction.

1. $\hat{\beta} = (1.6573, -0.6633, -4.0820)$, $\text{SCR} = 0.429$.
2. $\hat{\beta} = (2.1363, -0.9046, -5.5430)$, $\text{SCR} = 0.387$.
On a changé une seule valeur d'un facteur 1.03, soit 3% de variation relative, et cela occasionne un changement de l'ordre de 20% à 30% de la valeur des coefficients. Cela indique que la régression est instable.
3. Premier cas (valeur = 10.3) : $\hat{\beta} = (0.3878, -0.0321, -0.3077)$, $\text{SCR} = 0.512$.
Deuxième cas (valeur = 10) : $\hat{\beta} = (0.3970, -0.0369, -0.3365)$, $\text{SCR} = 0.510$.

4. Les SCR après régularisation sont plus élevées qu'avant, ce qui est attendu, puisqu'on ne cherche plus à minimiser la SCR seule. Cela dit, la SCR reste du même ordre de grandeur.

Les paramètres de régression sont extrêmement différents avec et sans régularisation. Mais, avec régularisation, le fait de choisir 10.3 ou 10 change très peu les paramètres de régression obtenus (de l'ordre de 10%). La régression ridge donne donc ici des paramètres plus stables.