

# TD d'analyse de données n°5

## L3 MIAE (Informatique) S1, Université Paris Dauphine – PSL

Attention : calculatrice ou ordinateur (Python + NumPy) recommandé

### Exercice 1 : ACP et variance

Soit  $\mathbf{X} \in \mathbb{R}^{n \times p}$  un tableau de données contenant  $n$  observations  $X_i \in \mathbb{R}^p$ . Le but de cet exercice est d'examiner le lien entre les axes principaux et la covariance du tableau de données.

#### Questions.

1. Soient  $\mathbf{u} \in \mathbb{R}^p$  un vecteur de norme 1 et  $Z$  une série de données contenant les valeurs  $z_i = \mathbf{u}^T X_i$ . On note  $\mathbf{z} = (z_1, \dots, z_n) \in \mathbb{R}^n$ .  
Exprimer  $\bar{Z}$  en fonction de  $\bar{X} \in \mathbb{R}^p$ .
2. Exprimer la variance empirique de  $Z$  de façon matricielle.  
On notera  $\tilde{\mathbf{X}} = \mathbf{X} - \mathbf{1}_p \bar{X}^T$  le tableau des données centrées, où  $\mathbf{1}_n = (1, \dots, 1) \in \mathbb{R}^n$ .
3. Fournir un vecteur unitaire  $\mathbf{u} \in \mathbb{R}^p$  maximisant la variance empirique de  $Z$ .  
Indice : on pourra s'aider des éléments propres de la matrice  $\tilde{\mathbf{X}}^T \tilde{\mathbf{X}}$ .
4. Quel lien existe-t-il entre le vecteur  $\mathbf{u}$  trouvé à la question précédente et l'ACP ?

### Exercice 2 : ACP simple

On considère le tableau de données suivant :

|     |    |     |    |    |   |   |    |   |
|-----|----|-----|----|----|---|---|----|---|
| $X$ | 8  | -1  | 14 | 13 | 5 | 3 | 9  | 6 |
| $Y$ | 13 | -10 | 23 | 28 | 8 | 9 | 21 | 3 |

On travaillera sur la *transposée* de ce tableau, notée  $\mathbf{X} \in \mathcal{M}_{n,p}$ , avec  $n = 8$  observations (une par *ligne*) et  $p = 2$  variables (une par *colonne*).

#### Questions.

1. Calculer la moyenne et l'écart-type des deux séries de données.
2. Effectuer le centrage et la réduction des données. On notera  $\tilde{\mathbf{X}}$  le tableau des données centré réduit.
3. Calculer la matrice  $\mathbf{C}$  de corrélation des données  $\mathbf{X}$ .

4. Démontrer que, pour toute matrice de données  $\mathbf{X} \in \mathcal{M}_{n,p}$ ,  $\tilde{\mathbf{X}}^T \tilde{\mathbf{X}} = n\mathbf{C}$ .
5. Effectuer l'analyse en composantes principales des données en dimension  $d = 1$ , c'est-à-dire en ne conservant que l'axe principal :
  - (a) vérifier que les vecteurs :

$$v_1 = (0.707, 0.707) \qquad v_2 = (-0.707, 0.707)$$

sont des vecteurs propres de  $\tilde{\mathbf{X}}^T \tilde{\mathbf{X}}$  et fournir les valeurs propres qui leur sont associées.

- (b) tracer le nuage de points  $\tilde{\mathbf{X}}$  ainsi que l'axe principal ;
- (c) tracer le nuage de points  $\mathbf{X}$  ainsi que l'axe principal (que l'on devra transformer au préalable).

### Exercice 3 : ACP en dimension supérieure

On étudie la solvabilité des clients d'une banque en fonction de plusieurs caractéristiques :

|        |      |      |      |      |      |      |      |      |
|--------|------|------|------|------|------|------|------|------|
| Income | 73   | 27   | 29   | 20   | 128  | 49   | 17   | 17   |
| Limit  | 6600 | 3600 | 2500 | 1900 | 9800 | 6800 | 1300 | 2700 |
| Rating | 470  | 260  | 190  | 180  | 680  | 500  | 140  | 230  |
| Age    | 43   | 35   | 30   | 76   | 67   | 55   | 65   | 32   |

Pour chaque client, les variables sont les suivantes :

- Income : revenus annuels (en milliers de dollars) ;
- Limit : limite de découvert (en dollars) ;
- Rating : score de crédit ;
- Age : âge du client.

#### Questions.

1. Effectuer le pré-traitement des données. On note  $\mathbf{X}$  le tableau des données pré-traitées et  $\mathbf{A} = \mathbf{X}^T \mathbf{X}$ . Vérifier que les vecteurs suivants sont des vecteurs propres de  $\mathbf{A}$  et fournir les valeurs propres associées  $\lambda_1$  et  $\lambda_2$  :

$$v_1 = (-0.5638, -0.5701, -0.5712, -0.1756)$$

$$v_2 = (0.02984, 0.1575, 0.1148, -0.9804).$$

On admettra que les deux dernières valeurs propres ont les valeurs suivantes :  $\lambda_3 = 0.628$  et  $\lambda_4 = 0.00689$ .

2. Calculer la variance expliquée par chacun des axes, puis par les ACP effectuées avec  $d = 1, 2, 3, 4$ . Est-il raisonnable de faire une ACP avec deux axes principaux ?
3. Considérons l'ACP effectuée avec deux axes principaux ( $d = 2$ ). Interpréter le résultat à l'aide des coordonnées des vecteurs directeurs des deux axes principaux.
4. Tracer le cercle de corrélations et interpréter.