

TD d'analyse de données n°5

L3 MIAE (Informatique) S1, Université Paris Dauphine – PSL

Attention : calculatrice ou ordinateur (Python + NumPy) recommandé

Exercice 1 : ACP et variance

Soit $\mathbf{X} \in \mathbb{R}^{n \times p}$ un tableau de données contenant n observations $X_i \in \mathbb{R}^p$. Le but de cet exercice est d'examiner le lien entre les axes principaux et la covariance du tableau de données.

Questions.

1. Soient $\mathbf{u} \in \mathbb{R}^p$ un vecteur de norme 1 et Z une série de données contenant les valeurs $z_i = \mathbf{u}^T X_i$. On note $\mathbf{z} = (z_1, \dots, z_n) \in \mathbb{R}^n$.
Exprimer $\bar{Z}$ en fonction de $\bar{X} \in \mathbb{R}^p$.
2. Exprimer la variance empirique de Z de façon matricielle.
On notera $\tilde{\mathbf{X}} = \mathbf{X} - \mathbf{1}_p \bar{X}^T$ le tableau des données centrées, où $\mathbf{1}_n = (1, \dots, 1) \in \mathbb{R}^n$.
3. Fournir un vecteur unitaire $\mathbf{u} \in \mathbb{R}^p$ maximisant la variance empirique de Z .
Indice : on pourra s'aider des éléments propres de la matrice $\tilde{\mathbf{X}}^T \tilde{\mathbf{X}}$.
4. Quel lien existe-t-il entre le vecteur $\mathbf{u}$ trouvé à la question précédente et l'ACP ?

Correction.

1. On a :

$$\bar{Z} = \frac{1}{n} \sum_{i=1}^n z_i = \frac{1}{n} \sum_{i=1}^n \mathbf{u}^T X_i = \frac{1}{n} \mathbf{u}^T \sum_{i=1}^n X_i = \mathbf{u}^T \bar{X}.$$

2. On a :

$$\begin{aligned} \overline{\text{Var}}(Z) &= \frac{1}{n} \sum_{i=1}^n (z_i - \bar{Z})^2 = \frac{1}{n} \sum_{i=1}^n (\mathbf{u}^T X_i - \mathbf{u}^T \bar{X})^2 = \frac{1}{n} \sum_{i=1}^n [\mathbf{u}^T (X_i - \bar{X})]^2 \\ &= \frac{1}{n} \sum_{i=1}^n [(X_i - \bar{X})^T \mathbf{u}]^2 = \frac{1}{n} \|\mathbf{a}\|^2, \end{aligned}$$

où :

$$\mathbf{a} = \begin{pmatrix} (X_1 - \bar{X})^T \mathbf{u} \\ \vdots \\ (X_n - \bar{X})^T \mathbf{u} \end{pmatrix} = \begin{pmatrix} (X_1 - \bar{X})^T \\ \vdots \\ (X_n - \bar{X})^T \end{pmatrix} \mathbf{u} = \left[\begin{pmatrix} X_1^T \\ \vdots \\ X_n^T \end{pmatrix} - \begin{pmatrix} \bar{X}^T \\ \vdots \\ \bar{X}^T \end{pmatrix} \right] \mathbf{u} = \tilde{\mathbf{X}} \mathbf{u}.$$

Donc $\overline{\text{Var}}(Z) = \frac{1}{n} \|\tilde{\mathbf{X}}\mathbf{u}\|^2 = \frac{1}{n} \mathbf{u}^T \tilde{\mathbf{X}}^T \tilde{\mathbf{X}} \mathbf{u}$.

3. La matrice $\tilde{\mathbf{X}}^T \tilde{\mathbf{X}}$ est symétrique semi-définie positive, donc elle est diagonalisable en base orthonormale avec des valeurs propres positives ou nulles :

$$\tilde{\mathbf{X}}^T \tilde{\mathbf{X}} = \mathbf{U} \mathbf{\Sigma} \mathbf{U}^T,$$

où $\mathbf{U} \in \mathbb{R}^{p \times p}$ est une matrice orthogonale et $\mathbf{\Sigma} = \text{Diag}(\sigma_1, \dots, \sigma_p)$ avec $\sigma_1 \geq \dots \geq \sigma_p \geq 0$. Par conséquent :

$$\begin{aligned} \overline{\text{Var}}(Z) &= \frac{1}{n} \mathbf{u}^T \tilde{\mathbf{X}}^T \tilde{\mathbf{X}} \mathbf{u} = \frac{1}{n} \mathbf{u}^T \mathbf{U} \mathbf{\Sigma} \mathbf{U}^T \mathbf{u} \\ &= \frac{1}{n} (\mathbf{U}^T \mathbf{u})^T \mathbf{\Sigma} \mathbf{U}^T \mathbf{u}. \end{aligned}$$

Comme $\mathbf{U}$ est inversible, alors trouver $\mathbf{u}$ maximisant $(\mathbf{U}^T \mathbf{u})^T \mathbf{\Sigma} \mathbf{U}^T \mathbf{u}$ est équivalent à trouver $\mathbf{v} = \mathbf{U}^T \mathbf{u}$ maximisant $\mathbf{v}^T \mathbf{\Sigma} \mathbf{v}$. De plus, comme $\mathbf{U}$ est une matrice orthogonale, on a nécessairement $\|\mathbf{v}\| = \|\mathbf{u}\|$.

On a donc :

$$\overline{\text{Var}}(Z) = \frac{1}{n} \mathbf{v}^T \mathbf{\Sigma} \mathbf{v} = \frac{1}{n} \sum_{i=1}^p \sigma_i v_i^2,$$

qui est maximale lorsque $v_1 = 1$ et $v_i = 0$ pour tout $i \geq 2$ (puisque $\sigma_1 = \max(\sigma_1, \dots, \sigma_p)$), soit :

$$\mathbf{v} = \begin{pmatrix} 1 \\ 0 \\ \vdots \\ 0 \end{pmatrix} = \mathbf{e}_1.$$

Donc un vecteur $\mathbf{u}$ maximisant $\overline{\text{Var}}(Z)$ est : $\mathbf{u} = \mathbf{U} \mathbf{e}_1$ (en supposant que les valeurs propres de $\mathbf{\Sigma}$ sont triées par ordre décroissant).

4. Le premier axe principal donné par l'ACP est la première colonne de $\mathbf{U}$, matrice construite à la question précédente. Cette colonne est égale à $\mathbf{U} \mathbf{e}_1$.

Exercice 2 : ACP simple

On considère le tableau de données suivant :

X	8	-1	14	13	5	3	9	6
Y	13	-10	23	28	8	9	21	3

On travaillera sur la *transposée* de ce tableau, notée $\mathbf{X} \in \mathcal{M}_{n,p}$, avec $n = 8$ observations (une par *ligne*) et $p = 2$ variables (une par *colonne*).

Questions.

1. Calculer la moyenne et l'écart-type des deux séries de données.
2. Effectuer le centrage et la réduction des données. On notera $\tilde{\mathbf{X}}$ le tableau des données centré réduit.
3. Calculer la matrice $\mathbf{C}$ de corrélation des données $\mathbf{X}$.
4. Démontrer que, pour toute matrice de données $\mathbf{X} \in \mathcal{M}_{n,p}$, $\tilde{\mathbf{X}}^T \tilde{\mathbf{X}} = n\mathbf{C}$.
5. Effectuer l'analyse en composantes principales des données en dimension $d = 1$, c'est-à-dire en ne conservant que l'axe principal :
 - (a) vérifier que les vecteurs :

$$v_1 = (0.707, 0.707) \qquad v_2 = (-0.707, 0.707)$$

sont des vecteurs propres de $\tilde{\mathbf{X}}^T \tilde{\mathbf{X}}$ et fournir les valeurs propres qui leur sont associées.

- (b) tracer le nuage de points $\tilde{\mathbf{X}}$ ainsi que l'axe principal ;
- (c) tracer le nuage de points $\mathbf{X}$ ainsi que l'axe principal (que l'on devra transformer au préalable).

Correction.

1. $\bar{X} = 7.125$, $\sigma_X = 4.675$, $\bar{Y} = 11.875$, $\sigma_Y = 11.450$.
2. Tableau des données centrées réduites :

$\tilde{X}$	0.187	-1.738	1.470	1.257	-0.455	-0.882	0.401	-0.241
$\tilde{Y}$	0.098	-1.910	0.972	1.408	-0.338	-0.251	0.797	-0.775

3. Matrice de corrélations $\mathbf{C}$:

	X	Y
X	1.00	0.93
Y	0.93	1.00

4. Soit $\mathbf{X} \in \mathcal{M}_{n,p}$ un tableau de données quelconque. Le coefficient à l'emplacement (i, j) de la matrice $\tilde{\mathbf{X}}^T \tilde{\mathbf{X}}$ est :

$$\tilde{X}^{(i)T} \tilde{X}^{(j)}.$$

Il suffit de poser le calcul du produit des matrices $\tilde{\mathbf{X}}^T$ et $\tilde{\mathbf{X}}$, de décomposer $\tilde{\mathbf{X}}$ selon ses colonnes $(\tilde{X}^{(1)}, \dots, \tilde{X}^{(p)})$ et de décomposer $\tilde{\mathbf{X}}^T$ selon ses lignes $(\tilde{X}^{(1)T}, \dots, \tilde{X}^{(p)T})$.

Puis on a :

$$\begin{aligned} \tilde{X}^{(i)T} \tilde{X}^{(j)} &= \sum_{k=1}^n \tilde{X}_k^{(i)} \tilde{X}_k^{(j)} \\ &= \sum_{k=1}^n \left(\frac{X_k^{(i)} - \bar{X}^{(i)}}{\sigma_{X^{(i)}}} \right) \left(\frac{X_k^{(j)} - \bar{X}^{(j)}}{\sigma_{X^{(j)}}} \right) \\ &= n \operatorname{corr}(X^{(i)}, X^{(j)}), \end{aligned}$$

ce qui achève de répondre à la question.

5. Réponses :

- (a) Il faut diagonaliser la matrice $\mathbf{A} = \tilde{\mathbf{X}}^T \tilde{\mathbf{X}}$ en base orthonormale. Comme celle-ci est symétrique réelle, cela est possible.

Pour vérifier que v_1 est un vecteur propre de $\mathbf{A}$, on calcule $u_1 := \mathbf{A}v_1$, puis on vérifie que :

$$\frac{(u_1)_1}{(v_1)_1} = \frac{(u_1)_2}{(v_1)_2}.$$

Cela fait, la valeur propre associée λ_1 est égale à $\frac{(u_1)_1}{(v_1)_1}$.

Puis on fait la même opération avec v_2 , en calculant $u_2 := \mathbf{A}v_2$, puis en vérifiant que :


$$\frac{(u_2)_1}{(v_2)_1} = \frac{(u_2)_2}{(v_2)_2}.$$

Les éléments propres valent donc :


$$\begin{array}{ll} \lambda_1 = 15.4 & v_1 = (0.707, 0.707) \\ \lambda_2 = 0.582 & v_2 = (-0.707, 0.707). \end{array}$$

L'axe principal est colinéaire au vecteur $v_1 = (0.707, 0.707)$ et la valeur propre associée est $\lambda_1 = 15.4$;

(b) Figure :



(c) Figure (attention, échelle différente pour X et Y) :



Pour obtenir cette figure, il faut transformer l'axe principal en effectuant l'opération inverse de centrage et de réduction. On utilise v'_1 , obtenu en multipliant la première coordonnée de v_1 par σ_X , et la deuxième par σ_Y . Puis on translate ce vecteur au point $(\bar{X}, \bar{Y})$ du repère.

Exercice 3 : ACP en dimension supérieure

On étudie la solvabilité des clients d'une banque en fonction de plusieurs caractéristiques :

Income	73	27	29	20	128	49	17	17
Limit	6600	3600	2500	1900	9800	6800	1300	2700
Rating	470	260	190	180	680	500	140	230
Age	43	35	30	76	67	55	65	32

Pour chaque client, les variables sont les suivantes :

- Income : revenus annuels (en milliers de dollars) ;
- Limit : limite de découvert (en dollars) ;
- Rating : score de crédit ;
- Age : âge du client.

Questions.

1. Effectuer le pré-traitement des données. On note $\mathbf{X}$ le tableau des données pré-traitées et $\mathbf{A} = \mathbf{X}^T \mathbf{X}$. Vérifier que les vecteurs suivants sont des vecteurs propres de $\mathbf{A}$ et fournir les valeurs propres associées λ_1 et λ_2 :

$$v_1 = (-0.5638, -0.5701, -0.5712, -0.1756)$$

$$v_2 = (0.02984, 0.1575, 0.1148, -0.9804).$$

On admettra que les deux dernières valeurs propres ont les valeurs suivantes : $\lambda_3 = 0.628$ et $\lambda_4 = 0.00689$.

2. Calculer la variance expliquée par chacun des axes, puis par les ACP effectuées avec $d = 1, 2, 3, 4$. Est-il raisonnable de faire une ACP avec deux axes principaux ?
3. Considérons l'ACP effectuée avec deux axes principaux ($d = 2$). Interpréter le résultat à l'aide des coordonnées des vecteurs directeurs des deux axes principaux.
4. Tracer le cercle de corrélations et interpréter.

Correction.

1. On effectue le centrage et la réduction des données. On note $\mathbf{X}$ le résultat obtenu. On diagonalise $\mathbf{X}^T \mathbf{X}$ en base orthonormale. On note v_1, v_2, v_3, v_4 les vecteurs propres (formant une base orthonormale) et on note $\lambda_1, \lambda_2, \lambda_3, \lambda_4$ les valeurs propres associées (dans l'ordre décroissant).

Vecteurs directeurs des axes principaux :

$$\begin{aligned} v_1 &= (-0.56, -0.57, -0.57, -0.17) \\ v_2 &= (0.03, 0.16, 0.11, -0.98) \\ v_3 &= (0.82, -0.34, -0.45, -0.08) \\ v_4 &= (-0.07, 0.73, -0.68, 0.04). \end{aligned}$$

Note : la matrice $(v_1 \ v_2 \ v_3 \ v_4)$, où les v_i sont écrits sous la forme de vecteurs colonne, est la matrice $\mathbf{V}$ vue en cours avec $d = p = 4$.

Valeurs propres associées :

$$\lambda_1 = 23.8 \quad \lambda_2 = 7.56 \quad \lambda_3 = 0.628 \quad \lambda_4 = 0.00689.$$

2. On rappelle que la variance expliquée par le i -ème axe principal, notée ici k_i , est définie par la formule suivante :

$$k_i = \frac{\lambda_i}{\sum_{k=1}^4 \lambda_k}.$$

Par conséquent, la variance expliquée par chacun des axes est :

$$k_1 = 0.74 \quad k_2 = 0.24 \quad k_3 = 0.02 \quad k_4 = 0.00022.$$

On rappelle que la variance expliquée par l'ACP avec d axes principaux, notée ici K_d , est définie par la formule suivante :

$$K_d = \frac{\sum_{k=1}^d \lambda_k}{\sum_{k=1}^4 \lambda_k}.$$

Par conséquent, la variance expliquée par les ACP avec $d = 1, 2, 3, 4$ est :

$$K_1 = 0.74 \quad K_2 = 0.98 \quad K_3 = 0.99978 \quad K_4 = 1.$$

Si l'on est dans une situation où l'on peut négliger 2% de variance expliquée, alors il est raisonnable de faire une ACP avec $d = 2$.

3. La direction de plus forte variance des données (v_1) contient une contribution quasiment égale et de même signe des variables "Income", "Limit", "Rating". Quand à la deuxième direction, elle contient presque exclusivement la contribution de "Age". La variance du jeu de données est donc en grande partie expliquée par, d'un côté, une contribution globale des variables liées aux comptes en banque, et de l'autre, l'âge, lié au détenteur du compte.
4. On considère les deux axes principaux v_1 et v_2 .

Puis on calcule :


$$w_1 = (\mathbf{X}v_1)^T \quad w_2 = (\mathbf{X}v_2)^T.$$

Pour chaque variable $i \in \{1, \dots, 4\}$, on définit :

$$x_i := \text{corr}(X^{(i)}, w_1) \quad y_i := \text{corr}(X^{(i)}, w_2).$$

Puis on trace les 4 vecteurs de coordonnées (x_i, y_i) .

Figure :



Les vecteurs sont tous quasiment de norme 1, donc les deux axes principaux représentent assez fidèlement les 4 variables initiales. Par ailleurs, comme indiqué à la question précédente, 3 variables sont presque exclusivement expliquées par le premier axe, et 1 variable est expliquée par le second.