

# TD d'analyse de données n°6

L3 MIAAGE (Informatique) S1, Université Paris Dauphine – PSL

Attention : calculatrice recommandée

## Exercice 1 : Régression en Composantes Principales

On considère le tableau de données suivant :

|       |     |       |      |      |      |       |      |      |
|-------|-----|-------|------|------|------|-------|------|------|
| $X_1$ | 3   | -6    | 9    | 8    | 0    | -5    | 9    | 1    |
| $X_2$ | 0.2 | -18.2 | 12.2 | 10.3 | -6.0 | -15.9 | 11.8 | -4.0 |
| $Y$   | 1.0 | -1.8  | 2.5  | 2.5  | -0.5 | -2.0  | 3.0  | 0.5  |

On veut effectuer la régression linéaire de  $Y$  en fonction de  $(X_1, X_2)$ . On note  $\mathbf{Y} \in \mathbb{R}^8$  la série de données associée à  $Y$ , et  $\mathbf{X} \in \mathcal{M}_{8,2}$  le tableau de données contenant la variable  $X_1$  dans la première colonne et la variable  $X_2$  dans la deuxième.

### Questions.

1. Calculer  $\text{corr}(X_1, X_2)$ . Est-il judicieux de procéder directement à la régression linéaire demandée ?
2. Pré-traiter  $\mathbf{X}$ . On notera  $\tilde{\mathbf{X}}$  le tableau des données centrées réduites.
3. Calculer  $\mathbf{A} = \tilde{\mathbf{X}}^T \tilde{\mathbf{X}}$ .
4. Vérifier que les vecteurs  $v_1 = (0.707, 0.707)$  et  $v_2 = (-0.707, 0.707)$  sont des vecteurs propres de  $\mathbf{A}$  et indiquer les valeurs propres associées, que l'on notera  $\lambda_1$  et  $\lambda_2$ .
5. Effectuer l'ACP de  $\tilde{\mathbf{X}}$  en ne conservant que l'axe principal : déterminer le tableau  $\mathbf{Z} \in \mathcal{M}_{8,1}$  des données  $\tilde{\mathbf{X}}$  projetées sur l'axe principal.
6. Effectuer la régression linéaire de  $\mathbf{Z}$  en fonction de  $Y$ . On appellera  $\beta_1$  et  $\beta_0$  les coefficients de la régression :  $\hat{\mathbf{Y}} = \beta_1 \mathbf{Z} + \beta_0$ .
7. Exprimer  $\hat{\mathbf{Y}}$  en fonction de  $\tilde{\mathbf{X}}$ , puis exprimer  $\hat{\mathbf{Y}}$  en fonction de  $\mathbf{X}$ .

### Questions complémentaires.

1. Tracer le nuage de points  $(X_1, X_2)$ . Commenter la forme de ce nuage de points en s'aidant des valeurs trouvées pour  $\lambda_1$  et  $\lambda_2$ .

## Exercice 2 : ACP

On dispose de quatre variables : trois variables quantitatives  $X_1$ ,  $X_2$ ,  $X_3$ , et une variable catégorielle  $Y$ . Le but de l'exercice est de voir comment l'ACP peut servir d'outil pour classer des observations.

|       |    |    |   |     |   |    |    |      |
|-------|----|----|---|-----|---|----|----|------|
| $X_1$ | 0  | 0  | 1 | 0.5 | 0 | 0  | -1 | -0.5 |
| $X_2$ | 1  | -1 | 0 | 2   | 1 | 2  | 0  | 2    |
| $X_3$ | -1 | -1 | 0 | -2  | 1 | -2 | 0  | -2   |
| $Y$   | 1  | 0  | 0 | 1   | 0 | 1  | 0  | 1    |

On note  $\mathbf{X}$  le sous-tableau de données comportant les variables  $(X_1, X_2, X_3)$ .

### Questions.

1. Exceptionnellement, on ne fera aucun pré-traitement des variables.  
Calculer la matrice  $\mathbf{A} = \mathbf{X}^T \mathbf{X}$ .
2. La matrice  $\mathbf{A}$  possède un vecteur propre évident. Indiquer lequel ainsi que la valeur propre associée.
3. Vérifier que les vecteurs  $v_1 = (0, -0.707, 0.707)$  et  $v_2 = (0, -0.707, -0.707)$  sont des vecteurs propres. Quelles sont les valeurs propres associées ?
4. On effectue une ACP sur les données avec deux axes principaux. Proposer un vecteur directeur pour chacun des deux axes et rappeler les valeurs propres associées.
5. Tracer le nuage de points du tableau de données projeté sur les deux axes principaux. Pour chaque observation, tracer le point correspondant en utilisant une couleur dépendant de la valeur de  $Y$  (par exemple, tracer le point en bleu si  $Y = 0$ , et le tracer en orange si  $Y = 1$ ).
6. Commenter la position des points en fonction de leur valeur de  $Y$ . Proposer un critère permettant de séparer les points en fonction de leur valeur de  $Y$ .