

TD d'analyse de données n°6

L3 MIAAGE (Informatique) S1, Université Paris Dauphine – PSL

Attention : calculatrice recommandée

Exercice 1 : Régression en Composantes Principales

On considère le tableau de données suivant :

X_1	3	-6	9	8	0	-5	9	1
X_2	0.2	-18.2	12.2	10.3	-6.0	-15.9	11.8	-4.0
Y	1.0	-1.8	2.5	2.5	-0.5	-2.0	3.0	0.5

On veut effectuer la régression linéaire de Y en fonction de (X_1, X_2) . On note $\mathbf{Y} \in \mathbb{R}^8$ la série de données associée à Y , et $\mathbf{X} \in \mathcal{M}_{8,2}$ le tableau de données contenant la variable X_1 dans la première colonne et la variable X_2 dans la deuxième.

Questions.

1. Calculer $\text{corr}(X_1, X_2)$. Est-il judicieux de procéder directement à la régression linéaire demandée ?
2. Pré-traiter $\mathbf{X}$. On notera $\tilde{\mathbf{X}}$ le tableau des données centrées réduites.
3. Calculer $\mathbf{A} = \tilde{\mathbf{X}}^T \tilde{\mathbf{X}}$.
4. Vérifier que les vecteurs $v_1 = (0.707, 0.707)$ et $v_2 = (-0.707, 0.707)$ sont des vecteurs propres de $\mathbf{A}$ et indiquer les valeurs propres associées, que l'on notera λ_1 et λ_2 .
5. Effectuer l'ACP de $\tilde{\mathbf{X}}$ en ne conservant que l'axe principal : déterminer le tableau $\mathbf{Z} \in \mathcal{M}_{8,1}$ des données $\tilde{\mathbf{X}}$ projetées sur l'axe principal.
6. Effectuer la régression linéaire de $\mathbf{Z}$ en fonction de Y . On appellera β_1 et β_0 les coefficients de la régression : $\hat{\mathbf{Y}} = \beta_1 \mathbf{Z} + \beta_0$.
7. Exprimer $\hat{\mathbf{Y}}$ en fonction de $\tilde{\mathbf{X}}$, puis exprimer $\hat{\mathbf{Y}}$ en fonction de $\mathbf{X}$.

Questions complémentaires.

1. Tracer le nuage de points (X_1, X_2) . Commenter la forme de ce nuage de points en s'aidant des valeurs trouvées pour λ_1 et λ_2 .

Correction.

1. On a : $\text{corr}(X_1, X_2) \approx 1$. Dans ces circonstances, la régression linéaire est susceptible de fournir des résultats instables. On peut donc faire une régression ridge ou une régression en composantes principales.

2. $\bar{X}_1 = 2.375$, $\sigma_{X_1} = 5.611$, $\bar{X}_2 = -1.2$, $\sigma_{X_2} = 11.285$.

On pose : $\tilde{X}_1 = \frac{X_1 - \bar{X}_1}{\sigma_{X_1}}$ et $\tilde{X}_2 = \frac{X_2 - \bar{X}_2}{\sigma_{X_2}}$:

$\tilde{X}_1$	0.111	-1.493	1.181	1.002	-0.423	-1.314	1.181	-0.245
$\tilde{X}_2$	0.124	-1.506	1.187	1.019	-0.425	-1.303	1.152	-0.248

3. On a : $\mathbf{A} = \begin{pmatrix} 8 & 7.999 \\ 7.999 & 8 \end{pmatrix}$.

4. Pour montrer que v_1 est un vecteur propre de $\mathbf{A}$, on calcule $u_1 := \mathbf{A}v_1$, puis on vérifie que :

$$\frac{(u_1)_1}{(v_1)_1} = \frac{(u_1)_2}{(v_1)_2}.$$

Cela fait, la valeur propre associée λ_1 est égale à $\frac{(u_1)_1}{(v_1)_1}$.

Idem avec v_2 .

On trouve : $u_1 = (11.3, 11.3)$, donc $\lambda_1 = \frac{11.3}{0.707} = 16$

Et : $u_2 = (-0.000583, 0.000583)$, donc $\lambda_2 = \frac{-0.000583}{-0.707} = 0.000825$.

5. L'axe principal est celui associé à la valeur propre la plus grande, c'est-à-dire λ_1 . Il est dirigé par v_1 .

Les données projetées $\mathbf{Z}$ s'expriment donc : $\mathbf{Z} = \tilde{\mathbf{X}}v_1$.

Le tableau associé est :

Z	0.166	-2.120	1.674	1.429	-0.600	-1.850	1.649	-0.349
-----	-------	--------	-------	-------	--------	--------	-------	--------

6. On effectue la régression linéaire de Y en fonction de Z . Il s'agit d'une régression linéaire simple, on cherche à calculer β_1 , β_0 minimisant :

$$\text{SCR}(\beta_0, \beta_1) = \sum_{i=1}^n (Y_i - \beta_1 Z_i - \beta_0)^2$$

On rappelle que :

$$\begin{cases} \beta_0 &= \bar{Y} - \beta_1 \bar{Z}, \\ \beta_1 &= \frac{\sum_{i=1}^n (Z_i - \bar{Z})(Y_i - \bar{Y})}{\sum_{i=1}^n (Z_i - \bar{Z})^2}, \end{cases}$$

On trouve : $\beta_0 = 0.650$ et $\beta_1 = 1.283$.

7. On a : $\hat{\mathbf{Y}} = \beta_1 \mathbf{Z} + \beta_0$.

Comme $\mathbf{Z} = \tilde{\mathbf{X}}v_1$, on a : $\hat{\mathbf{Y}} = \beta_1 \tilde{\mathbf{X}}v_1 + \beta_0$.

On note v_{11} et v_{12} les coordonnées de v_1 : $v_1 = (v_{11}, v_{12})$. On a donc : $\hat{\mathbf{Y}} = \beta_1(\tilde{X}^{(1)}v_{11} + \tilde{X}^{(2)}v_{12}) + \beta_0$.

Pour démontrer cette identité, il suffit de poser le calcul matriciel :


$$\tilde{\mathbf{X}}v_1 = \begin{pmatrix} \tilde{X}^{(1)} & \tilde{X}^{(2)} \end{pmatrix} \times \begin{pmatrix} v_{11} \\ v_{12} \end{pmatrix} = \tilde{X}^{(1)}v_{11} + \tilde{X}^{(2)}v_{12}.$$

Ensuite :

$$\begin{aligned} \hat{\mathbf{Y}} &= \beta_1(\tilde{X}^{(1)}v_{11} + \tilde{X}^{(2)}v_{12}) + \beta_0 \\ &= \beta_1 \left(\frac{X^{(1)} - \bar{X}^{(1)}}{\sigma_{X^{(1)}}}v_{11} + \frac{X^{(2)} - \bar{X}^{(2)}}{\sigma_{X^{(2)}}}v_{12} \right) + \beta_0 \\ &= \frac{\beta_1 v_{11}}{\sigma_{X^{(1)}}}X^{(1)} + \frac{\beta_1 v_{12}}{\sigma_{X^{(2)}}}X^{(2)} - \beta_1 \left(\frac{\bar{X}^{(1)}}{\sigma_{X^{(1)}}} + \frac{\bar{X}^{(2)}}{\sigma_{X^{(2)}}} \right) + \beta_0. \end{aligned}$$

Correction des questions complémentaires.

1. Nuage de points :



Les points semblent parfaitement alignés, ce qui est cohérent avec une corrélation proche de 1 et avec une valeur propre λ_2 très inférieure à λ_1 . En effet, une dissymétrie aussi importante entre λ_1 et λ_2 indique que le nuage de points est très nettement plus étalé selon la direction v_1 que la direction v_2 .

Exercice 2 : ACP

On dispose de quatre variables : trois variables quantitatives X_1 , X_2 , X_3 , et une variable catégorielle Y . Le but de l'exercice est de voir comment l'ACP peut servir d'outil pour classer des observations.

X_1	0	0	1	0.5	0	0	-1	-0.5
X_2	1	-1	0	2	1	2	0	2
X_3	-1	-1	0	-2	1	-2	0	-2
Y	1	0	0	1	0	1	0	1

On note $\mathbf{X}$ le sous-tableau de données comportant les variables (X_1, X_2, X_3) .

Questions.

1. Exceptionnellement, on ne fera aucun pré-traitement des variables.
Calculer la matrice $\mathbf{A} = \mathbf{X}^T \mathbf{X}$.
2. La matrice $\mathbf{A}$ possède un vecteur propre évident. Indiquer lequel ainsi que la valeur propre associée.
3. Vérifier que les vecteurs $v_1 = (0, -0.707, 0.707)$ et $v_2 = (0, -0.707, -0.707)$ sont des vecteurs propres. Quelles sont les valeurs propres associées ?
4. On effectue une ACP sur les données avec deux axes principaux. Proposer un vecteur directeur pour chacun des deux axes et rappeler les valeurs propres associées.
5. Tracer le nuage de points du tableau de données projeté sur les deux axes principaux. Pour chaque observation, tracer le point correspondant en utilisant une couleur dépendant de la valeur de Y (par exemple, tracer le point en bleu si $Y = 0$, et le tracer en orange si $Y = 1$).
6. Commenter la position des points en fonction de leur valeur de Y . Proposer un critère permettant de séparer les points en fonction de leur valeur de Y .

Correction.

1. La matrice $\mathbf{A}$ vaut :

$$\mathbf{A} = \begin{pmatrix} 2.5 & 0 & 0 \\ 0 & 15 & -11 \\ 0 & -11 & 15 \end{pmatrix}.$$

2. La première ligne et la première colonne de la matrice $\mathbf{A}$ ne contiennent qu'une seule valeur non nulle. Cela signifie que le vecteur $e_1 = (1, 0, 0)$ est probablement un vecteur propre de $\mathbf{A}$. On remarque que $\mathbf{A}e_1 = 2.5e_1$, donc c'est bien le cas, et la valeur propre associée est 2.5.
3. Pour montrer que v_1 est un vecteur propre de $\mathbf{A}$, on calcule $u_1 := \mathbf{A}v_1$, puis on vérifie que :

$$\frac{(u_1)_2}{(v_1)_2} = \frac{(u_1)_3}{(v_1)_3}.$$

Ce n'est pas nécessaire de faire cette vérification pour $(v_1)_1$ et $(u_1)_1$, puisque ces deux valeurs sont nulles. Cela fait, la valeur propre associée λ_1 est égale à $\frac{(u_1)_2}{(v_1)_2}$.

Idem avec v_2 .


On trouve : $u_1 = (0, -18.382, 18.382)$, donc $\lambda_1 = \frac{18.382}{0.707} = 26$.

Aussi : $u_2 = (0, -2.828, -2.828)$, donc $\lambda_2 = \frac{-2.828}{-0.707} = 4$.

4. Les valeurs propres de $\mathbf{A}$ sont donc : $(26, 4, 2.5)$, et les vecteurs propres associés sont respectivement : (v_1, v_2, e_1) . Les vecteurs propres correspondant aux deux plus grandes valeurs propres sont donc (v_1, v_2) . Les deux axes principaux sont donc dirigés par v_1 et par v_2 .
5. On calcule les coordonnées des observations dans la base (v_1, v_2) . Pour ce faire, on pose la matrice $\mathbf{V} \in \mathcal{M}_{3,2}$ dont les colonnes sont (v_1, v_2) , puis on calcule :

$$\mathbf{Z} := \mathbf{XV}.$$

Il ne reste qu'à tracer le nuage de points correspondant à $\mathbf{Z}$, en notant que les points d'index $(1, 4, 6, 8)$ et ceux d'index $(2, 3, 5, 7)$ doivent avoir des couleurs différentes (puisque'ils ont une valeur de Y différente) :



Note : certains points sont superposés.

On peut séparer les points ayant une valeur de Y différente à l'aide d'une droite verticale d'abscisse -0.7 , par exemple.

Commentaire : la droite tracée peut être utilisée pour prédire la valeur de Y de nouvelles données, dont on ne connaît que les valeurs (X_1, X_2, X_3) . Pour une nouvelle donnée X , il suffit de calculer ses coordonnées Z dans la base des axes principaux, tracer le point, et vérifier si celui-ci se situe à gauche ou à droite du séparateur.