

# TD d'analyse de données n°7

## L3 MIAAGE (Informatique) S1, Université Paris Dauphine – PSL

### Exercice 1 : Test simple de corrélation

On considère le tableau de données suivant :

|     |    |     |    |    |    |    |    |    |
|-----|----|-----|----|----|----|----|----|----|
| $X$ | 3  | -6  | 9  | 8  | 0  | -5 | 9  | 1  |
| $Y$ | -5 | -14 | -4 | -6 | -5 | -9 | -4 | -3 |

On cherche à savoir s'il est raisonnable de considérer que les variables  $X$  et  $Y$  sont corrélées. On note  $\rho$  la corrélation sous-jacente.

#### Questions.

1. Calculer la corrélation empirique de  $(X, Y)$ , que l'on notera  $r$ .
2. On cherche à savoir si  $\rho$  est nul ou non. Rappeler les hypothèses  $\mathbb{H}_0$  et  $\mathbb{H}_1$  du test vu en cours.
3. Calculer la statistique de test  $T$  sur l'échantillon, qu'on notera  $t$ .
4. À l'aide du tableau fourni, donner les seuils  $t_{0.05}$  et  $t_{0.02}$ , associés respectivement aux niveaux  $\alpha = 0.05$  et  $\alpha = 0.02$ .
5. En déduire un encadrement de la p-valeur associée à  $t$ .
6. Avec le niveau  $\alpha = 0.05$ , doit-on conserver ou rejeter l'hypothèse nulle ? Et avec le niveau  $\alpha = 0.02$  ?
7. Finalement, on décide de choisir  $\alpha = 0.02$ . Est-il raisonnable de considérer que les deux variables sont non corrélées ? Mettre ce résultat en parallèle avec la corrélation  $r$  calculée précédemment et commenter.

### Exercice 2 : Test sur les paramètres d'une régression linéaire

On considère le tableau de données suivant :

|     |    |    |    |   |    |    |    |     |
|-----|----|----|----|---|----|----|----|-----|
| $X$ | 1  | 6  | -4 | 7 | 2  | -1 | 9  | -3  |
| $Y$ | -9 | -4 | -5 | 0 | -1 | -6 | -1 | -10 |

On suppose que les données ont été générées de la façon suivante :

$$Y_i = \beta_0 + \beta_1 X_i + \epsilon_i$$

où les  $\epsilon_i$  sont des variables aléatoires gaussiennes indépendantes et identiquement distribuées.

### Questions (1).

1. Effectuer la régression linéaire de  $Y$  en fonction de  $X$ . On notera  $\hat{\beta}_0$  et  $\hat{\beta}_1$  les coefficients de la régression :  $\hat{Y}_i = \hat{\beta}_0 + \hat{\beta}_1 X_i$ .
2. On souhaite savoir s'il est raisonnable de considérer que  $\beta_1 = 0$  (il n'y a pas de relation entre  $X$  et  $Y$ ). Définir les hypothèses du test statistique.
3. Calculer la valeur de la statistique  $F$  vue en cours sur cet échantillon. On la notera  $f$ .
4. Encadrer la p-valeur associée à cette statistique en utilisant la table.
5. Au-dessus de quel niveau  $\alpha$  doit-on rejeter  $\mathbb{H}_0$  ?

### Questions (2).

1. Soient  $\tilde{X}$  et  $\tilde{Y}$  deux variables aléatoires continues telles que :  $\tilde{Y} = \beta_0 + \beta_1 \tilde{X} + \epsilon$ , où  $\epsilon \sim \mathcal{N}(0, \sigma^2)$ , et  $\epsilon$  est indépendante de  $\tilde{X}$ .  
Exprimer  $\rho = \text{corr}(\tilde{X}, \tilde{Y}) = \frac{\mathbb{E}[(\tilde{X} - \mathbb{E}\tilde{X})(\tilde{Y} - \mathbb{E}\tilde{Y})]}{\sigma_{\tilde{X}} \sigma_{\tilde{Y}}}$ , en fonction de  $\sigma_{\tilde{X}}$ ,  $\sigma_{\tilde{Y}}$  et  $\beta_1$ .
2. On veut savoir s'il est raisonnable de considérer que  $\rho = 0$  en effectuant un test de corrélation. Définir les hypothèses, calculer la statistique de test (qu'on notera  $t$ ), et encadrer la p-valeur associée.
3. Comparer avec l'encadrement obtenu dans la première partie de l'exercice. Dans le cas étudié, quel est le test le plus informatif ? Justifier.