

TD d'analyse de données n°7

L3 MIAE (Informatique) S1, Université Paris Dauphine – PSL

Exercice 1 : Test simple de corrélation

On considère le tableau de données suivant :

X	3	-6	9	8	0	-5	9	1
Y	-5	-14	-4	-6	-5	-9	-4	-3

On cherche à savoir s'il est raisonnable de considérer que les variables X et Y sont corrélées. On note ρ la corrélation sous-jacente.

Questions.

1. Calculer la corrélation empirique de (X, Y) , que l'on notera r .
2. On cherche à savoir si ρ est nul ou non. Rappeler les hypothèses $\mathbb{H}_0$ et $\mathbb{H}_1$ du test vu en cours.
3. Calculer la statistique de test T sur l'échantillon, qu'on notera t .
4. À l'aide du tableau fourni, donner les seuils $t_{0.05}$ et $t_{0.02}$, associés respectivement aux niveaux $\alpha = 0.05$ et $\alpha = 0.02$.
5. En déduire un encadrement de la p-valeur associée à t .
6. Avec le niveau $\alpha = 0.05$, doit-on conserver ou rejeter l'hypothèse nulle ? Et avec le niveau $\alpha = 0.02$?
7. Finalement, on décide de choisir $\alpha = 0.02$. Est-il raisonnable de considérer que les deux variables sont non corrélées ? Mettre ce résultat en parallèle avec la corrélation r calculée précédemment et commenter.

Correction.

1. Soit n le nombre d'observations. La corrélation empirique de l'échantillon est :

$$\overline{\text{corr}}(X, Y) = \frac{\frac{1}{n} \sum_{i=1}^n (X_i - \bar{X})(Y_i - \bar{Y})}{\sqrt{\frac{1}{n} \sum_{i=1}^n (X_i - \bar{X})^2} \sqrt{\frac{1}{n} \sum_{i=1}^n (Y_i - \bar{Y})^2}}.$$

On a donc : $r = 0.723$.

2. D'après le cours :
 - $\mathbb{H}_0 : \rho = 0$: corrélation nulle entre les variables ;

— $\mathbb{H}_1 : \rho \neq 0$: corrélation non nulle entre les variables.

3. D'après le cours :

$$t = r \sqrt{\frac{n-2}{1-r^2}}.$$

On a donc : $t = 2.563$.

4. D'après le cours, T suit une loi de Student $\mathcal{T}(n-2)$ à $n-2$ degrés de liberté. Avec $n = 8$, le nombre de degrés de liberté est : $n-2 = 6$. On regarde donc la ligne numéro 6.

Pour $\alpha = 0.05$, on regarde la colonne numéro 2. On a donc : $t_\alpha = t_{0.05} = 2.447$.

Pour $\alpha = 0.02$, on regarde la colonne numéro 3. On a donc : $t_\alpha = t_{0.02} = 3.143$.

5. Par définition, $\mathbb{P}(|T| \geq t_\alpha) = \alpha$.

Donc $\mathbb{P}(|T| \geq 2.447) = 0.05$ et $\mathbb{P}(|T| \geq 3.143) = 0.02$.

Puisque $2.563 \geq 2.447$, alors $\mathbb{P}(|T| \geq 2.447) \geq \mathbb{P}(|T| \geq 2.563)$.

De la même façon, puisque $3.143 \geq 2.563$, alors $\mathbb{P}(|T| \geq 2.563) \geq \mathbb{P}(|T| \geq 3.143)$.

Finalement : $\mathbb{P}(|T| \geq 2.447) \geq \mathbb{P}(|T| \geq 2.563) \geq \mathbb{P}(|T| \geq 3.143)$, c'est-à-dire : $0.05 \geq \mathbb{P}(|T| \geq 2.563) \geq 0.02$.

La p-valeur, (qui, par définition, est $\mathbb{P}(|T| \geq 2.563)$), est donc comprise entre 0.02 et 0.05 : $0.02 \leq p \leq 0.05$.

6. La p-valeur est inférieure à 0.05. Donc, avec le niveau $\alpha = 0.05$, on rejette $\mathbb{H}_0$.

La p-valeur est supérieure à 0.02. Donc, avec le niveau $\alpha = 0.02$, on conserve $\mathbb{H}_0$.

7. Avec $\alpha = 0.02$, on a vu qu'on conservait $\mathbb{H}_0$. On ne peut donc pas rejeter l'hypothèse de variables non corrélées.

On a obtenu $r = 0.723$, qui est une corrélation assez éloignée de 0. Il n'est pourtant pas déraisonnable d'affirmer que les variables sont non corrélées : on dispose d'un très faible nombre observations ($n = 8$), et il est possible que la corrélation observée soit simplement due au bruit (i.e., à l'aléa propre à l'échantillon), et non à une corrélation fondamentale entre X et Y .

Exercice 2 : Test sur les paramètres d'une régression linéaire

On considère le tableau de données suivant :

X	1	6	-4	7	2	-1	9	-3
Y	-9	-4	-5	0	-1	-6	-1	-10

On suppose que les données ont été générées de la façon suivante :

$$Y_i = \beta_0 + \beta_1 X_i + \epsilon_i$$

où les ϵ_i sont des variables aléatoires gaussiennes indépendantes et identiquement distribuées.

Questions (1).

1. Effectuer la régression linéaire de Y en fonction de X . On notera $\hat{\beta}_0$ et $\hat{\beta}_1$ les coefficients de la régression : $\hat{Y}_i = \hat{\beta}_0 + \hat{\beta}_1 X_i$.
2. On souhaite savoir s'il est raisonnable de considérer que $\beta_1 = 0$ (il n'y a pas de relation entre X et Y). Définir les hypothèses du test statistique.
3. Calculer la valeur de la statistique F vue en cours sur cet échantillon. On la notera f .
4. Encadrer la p-valeur associée à cette statistique en utilisant la table.
5. Au-dessus de quel niveau α doit-on rejeter $\mathbb{H}_0$?

Questions (2).

1. Soient $\tilde{X}$ et $\tilde{Y}$ deux variables aléatoires continues telles que : $\tilde{Y} = \beta_0 + \beta_1 \tilde{X} + \epsilon$, où $\epsilon \sim \mathcal{N}(0, \sigma^2)$, et ϵ est indépendante de $\tilde{X}$.
Exprimer $\rho = \text{corr}(\tilde{X}, \tilde{Y}) = \frac{\mathbb{E}[(\tilde{X} - \mathbb{E}\tilde{X})(\tilde{Y} - \mathbb{E}\tilde{Y})]}{\sigma_{\tilde{X}} \sigma_{\tilde{Y}}}$, en fonction de $\sigma_{\tilde{X}}$, $\sigma_{\tilde{Y}}$ et β_1 .
2. On veut savoir s'il est raisonnable de considérer que $\rho = 0$ en effectuant un test de corrélation. Définir les hypothèses, calculer la statistique de test (qu'on notera t), et encadrer la p-valeur associée.
3. Comparer avec l'encadrement obtenu dans la première partie de l'exercice. Dans le cas étudié, quel est le test le plus informatif ? Justifier.

Correction (1).

1. On utilise les formules de la régression linéaire univariée :

$$\begin{aligned}\hat{\beta}_0 &= \bar{Y} - \hat{\beta}_1 \bar{X}, \\ \hat{\beta}_1 &= \frac{\sum_{i=1}^n (X_i - \bar{X})(y_i - \bar{Y})}{\sum_{i=1}^n (X_i - \bar{X})^2}.\end{aligned}$$

On a donc : $\hat{\beta}_0 = -5.67$ et $\hat{\beta}_1 = 0.55$.

2. D'après le cours :
 - $\mathbb{H}_0 : \beta_1 = 0$;
 - $\mathbb{H}_1 : \beta_1 \neq 0$.
3. D'après le cours :

$$F := \frac{\frac{\sum_{i=1}^n (\hat{Y}_i - \bar{Y})^2}{p}}{\frac{\sum_{i=1}^n (\hat{Y}_i - Y_i)^2}{n-p-1}},$$

où $p = 1$ (régression par rapport à une seule variable) et $n = 8$. On a donc : $f = 5.92$.

4. Pour encadrer la p-valeur associée à f , on se réfère à la table de la loi de Fisher. Pour chaque $\alpha \in \{0.1, 0.05, 0.02, 0.01\}$, on regarde la valeur située colonne numéro $p = 1$, ligne numéro $n - p - 1 = 6$, on la reporte et on la note f_α .
Puis on regarde pour quels α^- et α^+ on a un encadrement serré $f_{\alpha^+} \leq f \leq f_{\alpha^-}$.
C'est le cas pour $\alpha^+ = 0.1$ et $\alpha^- = 0.05$: $f_{0.1} = 3.78 \leq 5.92 \leq 5.99 = f_{0.05}$.
La p-valeur associée à f est donc encadrée par 0.05 et 0.1.
5. On doit rejeter $\mathbb{H}_0$ pour tout niveau α supérieur ou égal à 0.1.

Correction (2).

1. On calcule :

$$\begin{aligned}\mathbb{E} \left[(\tilde{X} - \mathbb{E}\tilde{X})(\tilde{Y} - \mathbb{E}\tilde{Y}) \right] &= \mathbb{E} \left[(\tilde{X} - \mathbb{E}\tilde{X})(\beta_0 + \beta_1\tilde{X} + \epsilon - \mathbb{E}[\beta_0 + \beta_1\tilde{X} + \epsilon]) \right] \\ &= \mathbb{E} \left[(\tilde{X} - \mathbb{E}\tilde{X})(\beta_0 + \beta_1\tilde{X} + \epsilon - \beta_0 - \beta_1\mathbb{E}\tilde{X} - \mathbb{E}\epsilon) \right].\end{aligned}$$

Par définition de ϵ (il suit une loi normale de moyenne nulle), $\mathbb{E}\epsilon = 0$. Donc :

$$\begin{aligned}\mathbb{E} \left[(\tilde{X} - \mathbb{E}\tilde{X})(\tilde{Y} - \mathbb{E}\tilde{Y}) \right] &= \mathbb{E} \left[(\tilde{X} - \mathbb{E}\tilde{X})(\beta_1\tilde{X} + \epsilon - \beta_1\mathbb{E}\tilde{X}) \right] \\ &= \mathbb{E} \left[(\tilde{X} - \mathbb{E}\tilde{X})(\beta_1\tilde{X} - \beta_1\mathbb{E}\tilde{X}) \right] + \mathbb{E} \left[(\tilde{X} - \mathbb{E}\tilde{X})\epsilon \right].\end{aligned}$$

Comme ϵ et $\tilde{X}$ sont indépendantes, on a :

$$\mathbb{E} \left[(\tilde{X} - \mathbb{E}\tilde{X})\epsilon \right] = \mathbb{E}[\tilde{X} - \mathbb{E}\tilde{X}]\mathbb{E}[\epsilon] = \mathbb{E}[\tilde{X} - \mathbb{E}\tilde{X}] \cdot 0 = 0.$$

Donc :

$$\begin{aligned}\mathbb{E} \left[(\tilde{X} - \mathbb{E}\tilde{X})(\tilde{Y} - \mathbb{E}\tilde{Y}) \right] &= \mathbb{E} \left[(\tilde{X} - \mathbb{E}\tilde{X})(\beta_1\tilde{X} - \beta_1\mathbb{E}\tilde{X}) \right] \\ &= \beta_1\mathbb{E}[(\tilde{X} - \mathbb{E}\tilde{X})(\tilde{X} - \mathbb{E}\tilde{X})] \\ &= \beta_1\mathbb{E}[(\tilde{X} - \mathbb{E}\tilde{X})^2] \\ &= \beta_1\sigma_{\tilde{X}}^2,\end{aligned}$$

par définition de la variance $\sigma_{\tilde{X}}^2$.

Par conséquent :

$$\rho = \text{corr}(\tilde{X}, \tilde{Y}) = \frac{\mathbb{E}[(\tilde{X} - \mathbb{E}\tilde{X})(\tilde{Y} - \mathbb{E}\tilde{Y})]}{\sigma_{\tilde{X}}\sigma_{\tilde{Y}}} = \frac{\beta_1\sigma_{\tilde{X}}^2}{\sigma_{\tilde{X}}\sigma_{\tilde{Y}}} = \beta_1 \frac{\sigma_{\tilde{X}}}{\sigma_{\tilde{Y}}}.$$

2. On a :

- $\mathbb{H}_0 : \rho = 0$: corrélation nulle entre les variables ;
- $\mathbb{H}_1 : \rho \neq 0$: corrélation non nulle entre les variables ;
- $t = 2.43$;
- On regarde la table de la loi de Student à la ligne $n - 2 = 6$, et on cherche les α^+ , α^- consécutifs tels que $t_{\alpha^+} \leq t \leq t_{\alpha^-}$.
Pour $\alpha^+ = 0.1$ et $\alpha^- = 0.05$, on a : $t_{0.1} = 1.943 \leq 2.43 \leq 2.447 = t_{0.05}$.
La p-valeur associée à t est donc dans l'intervalle $[0.05, 0.1]$.
- On obtient le même encadrement que dans la première partie de l'exercice.
Dans ce cadre, les deux tests mènent à la même conclusion pour les niveaux α considérés : pour $\alpha \geq 0.1$, on rejette l'hypothèse nulle avec les deux tests ; pour $\alpha \leq 0.05$, on conserve l'hypothèse nulle avec les deux tests. Un test n'est pas plus informatif que l'autre pour déterminer s'il existe une relation linéaire entre les variables X et Y .