

TD d'analyse de données n°8

L3 MIAE (Informatique) S1, Université Paris Dauphine – PSL

Exercice : Test sur les coefficients d'une régression multivariée

On considère le tableau de données suivant :

X_1	3	-6	9	8	0	-5	9	1
X_2	0.2	-18.2	12.2	10.3	-6.0	-15.9	11.8	-4.0
Y	1.0	-1.8	2.5	2.5	-0.5	-2.0	3.0	0.5

On souhaite effectuer la régression de Y en fonction de $X^{(1)}$ et $X^{(2)}$, et on cherche à savoir s'il est raisonnable de ne considérer qu'une seule variable explicative.

On suppose que les données ont été générées de la façon suivante : $Y = \mathbf{X}\boldsymbol{\beta} + \boldsymbol{\epsilon}$, où $\mathbf{X} \in \mathcal{M}_{8,3}$ est la matrice des données (ne contenant que des 1 dans la troisième colonne), $\boldsymbol{\beta} = (\beta_1, \beta_2, \beta_3) \in \mathbb{R}^3$, et $\boldsymbol{\epsilon} \in \mathbb{R}^8$ est un vecteur contenant 8 gaussiennes indépendantes et identiquement distribuées.

Questions (1).

1. Effectuer la régression linéaire de Y en fonction de X_1 . On notera γ_0 et γ_1 les coefficients de la régression : $Y_i = \gamma_0 + \gamma_1 X_i^{(1)} + \epsilon_i^{(1)}$.
Tester s'il est raisonnable de considérer que $\gamma_1 = 0$ à l'aide d'un test de Fisher.
2. Effectuer la même chose avec la régression linéaire de Y en fonction de X_2 . On notera δ_0 et δ_1 les coefficients de la régression : $Y_i = \delta_0 + \delta_1 X_i^{(2)} + \epsilon_i^{(2)}$.
3. Effectuer la régression linéaire de Y en fonction de $(X^{(1)}, X^{(2)})$.
4. Proposer un test permettant de voir s'il est raisonnable de considérer que $\beta_2 = 0$:
 - (a) définir les hypothèses $\mathbb{H}_0$ et $\mathbb{H}_1$;
 - (b) calculer la statistique ;
 - (c) à l'aide des tableaux fournis, proposer un encadrement de la p-valeur.
5. Est-il raisonnable de considérer que $\beta_2 = 0$?
6. Comparer les réponses aux questions 2 et 5.
Que peut-on en déduire sur l'information contenue dans $X^{(1)}$ et $X^{(2)}$ par rapport à Y ?

Questions (2).

1. Proposer un test permettant de voir s'il est raisonnable de considérer que $\beta_1 = 0$.
Est-il raisonnable de considérer que $\beta_1 = 0$?
Conclure sur l'information contenue dans $X^{(1)}$ et $X^{(2)}$ par rapport à Y .
2. On remplace les valeurs de la série de données de $X^{(1)}$ par les suivantes :

$$X^{(1)} \mid 3 \quad 8 \quad -1 \quad 1 \quad 10 \quad 5 \quad 6 \quad 7$$

Le but est de vérifier si, dans ce cas, il est raisonnable de considérer que $\beta_2 = 0$:

- (a) effectuer la régression linéaire de Y par rapport à $X^{(1)}$;
- (b) tester s'il est raisonnable de considérer que $\beta_2 = 0$.

Correction (1).

1. D'après les formules du cours, on a :

$$\begin{aligned}\hat{\gamma}_0 &= \bar{Y} - \hat{\gamma}_1 \bar{X}^{(1)}, \\ \hat{\gamma}_1 &= \frac{\sum_{i=1}^n (X_i^{(1)} - \bar{X}^{(1)})(Y_i - \bar{Y})}{\sum_{i=1}^n (X_i^{(1)} - \bar{X}^{(1)})^2},\end{aligned}$$

donc : $\hat{\gamma}_0 = -0.118$, $\hat{\gamma}_1 = 0.323$.

Pour effectuer un test de Fisher, il faut d'abord définir les hypothèses :

- hypothèse $\mathbb{H}_0$: $\gamma_1 = 0$;
- hypothèse $\mathbb{H}_1$: $\gamma_1 \neq 0$.

D'après le cours, la statistique de test est :

$$F := \frac{\frac{\sum_{i=1}^n (\hat{Y}_i - \bar{Y})^2}{p}}{\frac{\sum_{i=1}^n (\hat{Y}_i - Y_i)^2}{n-p-1}},$$

où $\hat{Y}_i = \hat{\gamma}_0 + \hat{\gamma}_1 X_i^{(1)}$, $p = 1$ (régression par rapport à une seule variable) et $n = 8$.
On la calcule sur l'échantillon et on obtient $f = 303.25$.

Calcul de la p-valeur. Pour encadrer la p-valeur associée à f , on se réfère à la table de la loi de Fisher. Pour chaque $\alpha \in \{0.1, 0.05, 0.02, 0.01\}$, on regarde la valeur située colonne numéro $p = 1$, ligne numéro $n - p - 1 = 6$, on la reporte et on la note f_α .

Puis on regarde pour quels α^- et α^+ on a un encadrement serré $f_{\alpha^+} \leq f \leq f_{\alpha^-}$.

Dans le cas présent, la p-valeur la plus petite est $\alpha = 0.01$, avec $f_{0.01} = 13.7 < 303.25 = f$, donc on en déduit que la p-valeur associée à f est inférieure à 0.01.

Donc, avec un seuil $\alpha = 0.01$, on rejette $\mathbb{H}_0$: il est déraisonnable de considérer que $\gamma_1 = 0$.

2. On utilise les mêmes formules : $\hat{\delta}_0 = 0.843$, $\hat{\delta}_1 = 0.161$.

De manière similaire à la question précédente, on définit : $\hat{Y}_i = \hat{\delta}_0 + \hat{\delta}_1 X_i^{(2)}$.

Pour effectuer un test de Fisher, on définit les hypothèses :

- hypothèse $\mathbb{H}_0$: $\delta_1 = 0$;

— hypothèse $\mathbb{H}_1 : \delta_1 \neq 0$.

On calcule la statistique de test : $f = 276.08$.

Calcul de la p-valeur. Dans le cas présent, la p-valeur la plus petite est $\alpha = 0.01$, avec $f_{0.01} = 13.7 < 276.08 = f$, donc on en déduit que la p-valeur associée à f est inférieure à 0.01.

Donc, avec un seuil $\alpha = 0.01$, on rejette $\mathbb{H}_0$: il est déraisonnable de considérer que $\delta_1 = 0$.

3. En utilisant la notation de l'énoncé et la formule du cours pour la régression linéaire multiple, on a : $\hat{\beta} = (\mathbf{X}^T \mathbf{X})^{-1} \mathbf{X}^T \mathbf{Y}$.

On a donc : $\hat{\beta} = (1.657, -0.663, -4.082)$.

4. On suit la procédure :

(a) On veut tester s'il est raisonnable de considérer qu'il est inutile d'utiliser la variable $X^{(2)}$ dans la régression linéaire demandée. Les hypothèses sont :

— $\mathbb{H}_0 : \beta_2 = 0$,

— $\mathbb{H}_1 : \beta_2 \neq 0$;

(b) On utilise la formule du cours :

$$F := \frac{\frac{\sum_{i=1}^n (\hat{Y}_i^{1:p-q} - Y_i)^2 - \sum_{i=1}^n (\hat{Y}_i - Y_i)^2}{q}}{\frac{\sum_{i=1}^n (\hat{Y}_i - Y_i)^2}{n-p-1}},$$

où :

— $p = 2$ (deux variables de régression), $q = 1$ (une variable à tester),

— $\hat{Y}_i$ est la i -ième coordonnée de $\hat{\mathbf{Y}} = \mathbf{X}\hat{\beta}$,

— $\hat{Y}_i^{1:p-q}$ est l'estimation de Y_i en faisant la régression linéaire de Y par rapport à la première variable ($X^{(1)}$).

Donc : $\hat{Y}_i^{1:p-q} = \hat{\gamma}_0 + \hat{\gamma}_1 X_i^{(1)}$.

On obtient : $f = 1.077$;

- (c) Le nombre de degrés de liberté est de $q = 1$ pour le numérateur et $n - p - 1 = 8 - 2 - 1 = 5$ pour le dénominateur. On va donc se référer aux cases situées colonne 1, ligne 5 des tables de la loi de Fisher.

Dans le cas présent, la p-valeur la plus grande est $\alpha = 0.1$, avec $f_{0.1} = 4.06 > 1.077 = f$, donc on en déduit que la p-valeur associée à f est supérieure à 0.1.

5. Avec un seuil $\alpha = 0.1$, il est raisonnable de conserver l'hypothèse nulle : $\beta_2 = 0$.
6. D'après la question 2, l'importance de la variable $X^{(2)}$ pour estimer Y n'est pas négligeable (il n'est pas raisonnable de considérer $\delta_1 = 0$).

Or, la question 5 indique que, lorsqu'on a déjà effectué la régression de Y en fonction de $X^{(1)}$, ce n'est pas nécessaire d'ajouter $X^{(2)}$ dans les variables explicatives (il est raisonnable de considérer $\beta_2 = 0$).

Cela signifie que la variable $X^{(2)}$ ne permet pas d'améliorer significativement la régression de Y en fonction de $X^{(1)}$. Cela est certainement dû au fait que $X^{(2)}$ n'apporte pas plus d'information que $X^{(1)}$ pour prédire Y .

Correction (2).

1. On effectue les étapes suivantes :

(a) définition des hypothèses :

- hypothèse $\mathbb{H}_0 : \beta_1 = 0$,
- hypothèse $\mathbb{H}_1 : \beta_1 \neq 0$;

(b) calcul de la statistique :

$$F := \frac{\frac{\sum_{i=1}^n (\hat{Y}'_i - Y_i)^2 - \sum_{i=1}^n (\hat{Y}_i - Y_i)^2}{q}}{\frac{\sum_{i=1}^n (\hat{Y}_i - Y_i)^2}{n-p-1}},$$

où :

- $p = 2$ (deux variables de régression), $q = 1$ (une variable à tester),
- $\hat{Y}_i$ est la i -ième coordonnée de $\hat{\mathbf{Y}} = \mathbf{X}\hat{\boldsymbol{\beta}}$,
- $\hat{Y}'_i$ est l'estimation de Y_i en faisant la régression linéaire de Y par rapport à la deuxième variable ($X^{(2)}$).

Donc : $\hat{Y}'_i = \hat{\delta}_0 + \hat{\delta}_1 X_i^{(2)}$.

Rappel : on a déjà calculé $(\hat{\delta}_0, \hat{\delta}_1)$.

On obtient : $f = 1.663$;

(c) **Calcul de la p-valeur.** Le nombre de degrés de liberté est de $q = 1$ pour le numérateur et $n - p - 1 = 8 - 2 - 1 = 5$ pour le dénominateur. On va donc se référer aux cases situés colonne 1, ligne 5 des tables de la loi de Fisher.

Dans le cas présent, la p-valeur la plus grande est $\alpha = 0.1$, avec $f_{0.1} = 4.06 > 1.663 = f$, donc on en déduit que la p-valeur associée à f est supérieure à 0.1.

Donc, avec un seuil $\alpha = 0.1$, on conserve $\mathbb{H}_0$: il est raisonnable de considérer que $\beta_1 = 0$.

Finalement, peu importe la variable explicative choisie ($X^{(1)}$ ou $X^{(2)}$) pour la régression de Y , l'information apportée par l'autre variable est peu significative. Il est donc vraisemblable que $X^{(1)}$ et $X^{(2)}$ contiennent la même information sur Y .

2. (a) la régression linéaire de Y par rapport à $X^{(1)}$ donne : $\gamma_0 = 2.204$ et $\gamma_1 = -0.319$;

(b) **définition des hypothèses :**

- hypothèse $\mathbb{H}_0 : \beta_2 = 0$,
- hypothèse $\mathbb{H}_1 : \beta_2 \neq 0$.

Calcul de la statistique :

$$F := \frac{\frac{\sum_{i=1}^n (\hat{Y}_i^{1:p-q} - Y_i)^2 - \sum_{i=1}^n (\hat{Y}_i - Y_i)^2}{q}}{\frac{\sum_{i=1}^n (\hat{Y}_i - Y_i)^2}{n-p-1}},$$

où :

- $p = 2$ (deux variables de régression), $q = 1$ (une variable à tester),
- $\hat{Y}_i$ est la i -ième coordonnée de $\hat{\mathbf{Y}} = \mathbf{X}\hat{\boldsymbol{\beta}}$,
- $\hat{Y}_i^{1:p-q}$ est l'estimation de Y_i en faisant la régression linéaire de Y par rapport à la première variable ($X^{(1)}$).

Donc : $\hat{Y}_i^{1:p-q} = \hat{\gamma}_0 + \hat{\gamma}_1 X_i^{(1)}$.

On obtient : $f = 154.81$.

Calcul de la p-valeur. Le nombre de degrés de liberté est de $q = 1$ pour le numérateur et $n - p - 1 = 8 - 2 - 1 = 5$ pour le dénominateur. On va donc se référer aux cases situées colonne 1, ligne 5 des tables de la loi de Fisher.

Dans le cas présent, la p-valeur la plus petite est $\alpha = 0.01$, avec $f_{0.01} = 16.3 < 154.81 = f$, donc on en déduit que la p-valeur associée à f est inférieure à 0.01.

Donc, avec un seuil $\alpha = 0.01$, on rejette $\mathbb{H}_0$: il est déraisonnable de considérer que $\beta_2 = 0$. Autrement dit, la deuxième variable, $X^{(2)}$, contient de l'information significative à propos de Y .